

分类号: U49

10710-2020132074



长安大学

硕士学位论文

基于数据驱动的公路隧道通风设备
故障诊断方法研究

刘栩滔

导师姓名职称	许宏科 教授		
申请学位类别	工学硕士	学科专业名称	交通运输工程
论文提交日期	2023 年 4 月 14 日	论文答辩日期	2023 年 6 月 6 日
学位授予单位	长安大学		

Research on Fault Diagnosis Method of Highway Tunnel Ventilation Equipment Based on Data-driven

A Thesis Submitted for the Degree of Master

Candidate: Liu Xutao

Supervisor: Prof. Xu Hongke

Chang'an University, Xi'an, China

答辩委员会名单

答辩委员会	姓名	职称	工作单位
主席	路庆昌	教 授	长安大学
委员	高社生	教 授	西北工业大学
委员	许世燕	副教授	长安大学
委员	钱 超	副教授	长安大学
委员	许宏科	教 授	长安大学
秘书	林 杉	讲 师	长安大学

摘 要

随着公路隧道规模的增长,对公路隧道通风系统的要求也日益增加,公路隧道通风设备作为公路隧道通风系统的主要组成部分,对于公路隧道通风质量有着举足轻重的影响。因此,本文旨在通过模拟公路隧道通风设备故障并采集相应的故障数据,梳理公路隧道通风设备的故障特征,建立基于数据驱动的公路隧道通风设备故障诊断模型,为公路隧道通风设备的管理与维护提供决策参考。

本文首先通过分析公路隧道通风设备结构,确定通风设备结构主要为轴流式风机,并根据该结构特点设计和搭建了风机故障实验台。其次通过分析公路隧道通风风机故障,确定需要模拟的故障类型并完成正常运行、叶轮松动、转子断条、电压不足和固定件松动状态的故障模拟。然后设计并完成了故障采集系统,实现了风机故障实验台模拟故障的振动信号采集与存储,为公路隧道通风设备的故障诊断模型搭建提供数据支撑。其次对各种状态的风机数据集合经验模态分解后进行分析,结果表明虽然集合经验模态分解可以将原始数据分解为蕴含不同特征的本征模态函数,但是仍然不能直观表述故障类型,同时存在特征提取不充分的问题,除此之外不同本征模态函数所蕴含的故障特征也不同。因此提出一种基于集合经验模态分解与注意力机制的 EEMD-SE (Ensemble Empirical Mode Decomposition- Squeeze and Excitation) 故障诊断模型,对分解后的信号使用注意力机制进一步进行特征提取与故障类型判别,并且经过验证取得了良好的故障诊断效果。最后,基于目前公路隧道机电设备管理情况与公路隧道风机运行情况,提出了一种结合实时故障诊断功能的公路隧道风机监控系统。

在风机故障实验台采集的数据集上进行模型验证,结果表明本文提出的 EEMD-SE 公路隧道通风设备故障诊断模型其准确率可以达到 99.977%,具有较好的故障诊断性能,并且与其他几种经典算法相比具有较高的准确率。本文的研究成果可以为公路隧道通风设备的运营与维护提供决策支撑。

关键词: 公路隧道, 通风设备, 故障诊断, 神经网络

Abstract

As the scale of highway tunnels continues to increase, the requirements for ventilation systems in these tunnels are also increasing. Highway tunnel ventilation equipment, as a major component of the ventilation system, has a significant impact on the quality of tunnel ventilation. Therefore, this paper aims to simulate faults in highway tunnel ventilation equipment and collect relevant data to identify the characteristics of these faults, establish a data-driven fault diagnosis model for highway tunnel ventilation equipment, and provide decision-making support for the management and maintenance of such equipment.

Firstly, through an analysis of the structure of highway tunnel ventilation equipment, it was determined that the main structure is an axial flow fan. Based on this structural feature, a fan failure experimental platform was designed and built. Secondly, by analyzing ventilation fan failures in highway tunnels, the types of faults that needed to be simulated were determined. These included normal operation, loose impeller, broken rotor bar, insufficient voltage, and loose fixed components. A fault collection system was then designed and completed to collect and store vibration signals from the simulated fan failures, providing data support for the fault diagnosis model of highway tunnel ventilation equipment. The dataset of the various wind turbine states were analyzed after ensemble empirical mode decomposition (EEMD), and although EEMD can decompose raw data into intrinsic mode functions with different characteristics, it still cannot intuitively represent fault types, and there are problems with insufficient feature extraction. Furthermore, different intrinsic mode functions contain different fault features. Therefore, an EEMD-SE (Ensemble Empirical Mode Decomposition-Squeeze and Excitation) fault diagnosis model based on EEMD and attention mechanism was proposed, which further extracts features and discriminates fault types using an attention mechanism on the decomposed signal. It was validated to have good fault diagnosis performance. Finally, based on the current management status of highway tunnel electromechanical equipment and the operation status of highway tunnel fans, a highway tunnel fan monitoring system was proposed that combines real-time fault diagnosis functionality.

The EEMD-SE fault diagnosis model for highway tunnel ventilation equipment proposed in this paper was validated using the dataset collected from the fan failure experimental platform. The results showed that the accuracy of this model can reach 99.977%, indicating good fault diagnosis performance, and it performs better than several other classical algorithms. The research results of this paper can provide decision-making support for the operation and maintenance of highway tunnel ventilation equipment.

Keywords: Highway tunnel, ventilation equipment, fault diagnosis, neural network

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.3 研究内容与章节安排.....	5
第二章 公路隧道通风设备故障模拟方法研究	7
2.1 公路隧道通风设备分析.....	7
2.1.1 公路隧道通风设备类别分析.....	7
2.1.2 通风风机结构分析.....	9
2.1.3 公路隧道通风风机故障分析.....	10
2.2 公路隧道通风设备故障模拟方法	12
2.2.1 通风风机实验台结构.....	12
2.2.2 通风风机故障模拟方案.....	14
2.3 风机实验台故障数据采集方法	17
2.3.1 风机故障采样传感器.....	17
2.3.2 风机故障实验台通信.....	19
2.4 本章小结.....	23
第三章 公路隧道通风设备故障诊断方法研究	25
3.1 故障数据预处理方法.....	25
3.1.1 异常值处理方法.....	25
3.1.2 数据标准化方法.....	27
3.2 故障信号特征提取方法.....	28
3.2.1 小波变换.....	28
3.2.2 EMD 经验模态分解.....	30
3.2.3 EEMD 集合经验模态分解	33
3.3 基于 EEMD-SE 的故障诊断方法	35
3.3.1 卷积神经网络.....	35
3.3.2 通道注意力机制.....	38
3.3.3 故障诊断网络结构.....	41
3.4 本章小结.....	44
第四章 公路隧道通风设备故障诊断实验	45
4.1 通风设备故障数据与预处理	45
4.1.1 通风设备故障数据.....	45
4.1.2 故障数据异常值处理.....	47
4.1.3 故障数据归一化.....	48

4.2 基于 EEMD-SE 结构的通风设备故障诊断方法	51
4.2.1 EEMD 集合经验模态分解	51
4.2.2 实验结果分析	58
4.3 公路隧道通风设备监控系统	59
4.3.1 通风设备监控系统功能设计	59
4.3.2 隧道风机故障诊断模块结构设计	61
4.4 本章小结	63
总结与展望	65
总结	65
展望	66
参考文献	67

第一章 绪论

1.1 研究背景及意义

近年来,随着我国经济的平稳发展,高速公路的建设也在稳步推进,公路隧道通车里程数也同样迅速增长,截止 2021 年底,我国公路隧道共有 23268 处、总通车里程数为 2469.89 千米^[1],公路隧道的增长情况如图 1.1 所示。




图 1.1 我国公路隧道通车里程增长趋势图

公路隧道可以缩短行车里程,提高通行效率,减少复杂地形造成的交通事故,从而提高公路整体的通行能力,在整个公路路网尤其是高速公路中发挥着越来越重要的作用。然而公路隧道的正常运行不只是依靠基础土建设施,还必须依靠配套的隧道机电系统,隧道机电系统为隧道运营提供了照明、通风以及监控等功能,公路隧道机电系统的正常运行是保证隧道正常安全运营与高品质服务的必要条件。

车辆在隧道中通行时会排放尾气,其中含有 CO、NO、SO₂ 以及烟尘颗粒物等有害物质^[2],这些物质对人体的呼吸系统和神经系统有着较大的伤害,并且可以造成隧道内能见度降低的问题,从而加剧隧道内交通事故发生的可能性。同时有害物质还会对隧道结构与设施进行腐蚀,影响隧道寿命,因此隧道通风不仅关系着隧道运营的经济问题,还直接关系着隧道内人员的健康与安全问题。隧道通风通过引入外部的新鲜空气进入隧

道，稀释和排出有害气体，然而对于长、特长隧道，自然风和车流行驶产生的活塞风不足以完成通风的要求，这时就需要通风设备引入新鲜空气，因此通风设备决定着隧道通风系统的运行能否安全有效。隧道通风设备包括通风风机和静电除尘装置，其中通风风机数量多，起到的作用也更大。目前通风风机大多只有控制功能而缺少实时状态监测，若出现故障并且没有被及时发现，则可能影响整个隧道通风系统的运行。同时及时发现故障不仅可以消除隐患，还可以防止通风设备的进一步损坏，起到节约运营成本的作用。目前随着公路隧道信息化与智能化的发展，隧道内数据传输网络的搭建也为故障诊断系统提供了基础条件。

本研究旨在通过分析梳理公路隧道通风设备结构，确定通风设备主要结构特征，模拟该设备结构的故障并完成故障信息的采集，利用数据驱动的方式完成设备故障关键特征的提取以及故障诊断模型的构建；然后根据故障诊断模型，建立一个集监测、处理和信息发布功能的公路隧道通风设备监控系统，为之后的一系列维修保障措施提供数据支撑，以实现公路隧道通风设施的可靠、不间断运行，保障公路重点路段交通运行顺畅。

1.2 国内外研究现状

公路隧道通风设备作为实现隧道通风功能的主要部分，在公路隧道通风系统中发挥着至关重要的作用，及时发现通风设备故障并维护对公路隧道通风系统安全稳定的运行有着至关重要的作用。目前针对公路隧道通风设备故障已经有学者进行了研究，针对风机安装时的拉拔试验，钟正强^[3]等提出了一种隧道风机支承结构承载力检测的试验方法，并设计了相应的支承结构承载力检测装置，可以简单快捷的完成风机支承结构承载力检测。针对运营时隧道风机悬挂的稳定性问题，刘琦^[4]等提出了一种基于冲激响应的悬挂风机基础稳定性检测方法，并通过模拟试验和现场试验验证了方法的有效性。然而目前关于隧道通风设备故障的研究大多数集中在隧道顶部风机的固定问题，对于公路隧道通风设备在运营中的其他故障关注较少，并且仍不能满足对于公路隧道通风设备故障及时发现和及时诊断的需求。虽然目前对于公路隧道通风设备故障诊断的研究较少，但针对电机、轴承等机械的故障诊断研究较为深入^[5, 6]。

电机等机械的故障诊断的方法大致可以分为 3 类^[7, 8]，分别为基于数学模型、基于经验知识分析和基于数据驱动的方法。基于数学模型的方法主要是通过足够多的精确数

据,对目标进行较为精确的数学模型建模,这种方法需要对建模目标的结构机理有着详细深刻的认识,Niu^[9]等建立了高速滚珠轴承滚道局部表面缺陷振动的动力学模型,并通过实验验证了该模型能够有效地诊断故障高速滚动球轴承的振动响应。F Bagheri^[10]等通过分析电机的电气特性,提出了一种基于自适应卡尔曼滤波器的递归估计电机测量状态和参数的方法,并提出了针对定子故障的诊断模型。Zhao^[11]等采用归一化电流法对双三相永磁同步电动机的开路故障进行故障诊断,并在此基础上提出了一种基于电流模型预测的谐波失真容错控制策略。李宏^[12]等针对船舶推进系统中的无刷直流电机提出了一种参数估计方法,该方法通过测量电机的电压、电流和电机转速,辨识电机的转动惯量等参数,分析参数在运行时的变化从而获得故障信息。这些方法虽然存在理想状态的精确模型,然而现实存在机理模型由于目标结构复杂,参数较多或测量计算误差等因素,导致模型较难建立或建立不精准的问题。

基于经验知识的方法针对上述的建模困难问题提出了解决方法,Wu^[13]等通过模糊逻辑干扰和自适应阶次跟踪技术建立智能故障诊断系统数据库并提出了一种故障诊断专家系统。符号有向图方法^[14]同样应用于故障诊断中,刘友宽^[15]等基于符号有向图法提出了一种风力发电机组故障诊断方法,该方法通过遍历各故障节点传感器的数值,根据阈值判定节点故障从而判断故障源。然而这些方法同样存在当目标复杂,数据量过大时,出现建模困难、不准确或所需数据难以采集的问题^[16]。而基于数据驱动的方法进行故障诊断时往往不需要知道目标精确的物理模型,并且可以进一步提取故障信号特征,解决了上述方法在数据量大时建模困难的问题以及数据缺失建模不准确的而导致误差过大的问题^[17]。

基于数据驱动的方法大致有两种思路,一种是通过信号处理的方法,这种方法一般使用傅里叶变换、小波包等^[18,19]传统信号处理手段,通过各种中信号分析技术进行频域或者时域的特征分析,对目标振动、温度以及电压电流等信号进行处理,从而达到故障处理的目的。Burriel^[20]等提出了一种短频率的傅里叶变换,在电机的故障诊断中相较于短时傅里叶变化减少了所需的计算和存储资源。张邦基^[21]等针对滚动轴承提出了一种将小波变换与粗集理论结合的故障诊断方法,一定程度上解决了小波变换提取能量特征时需要精确计算特征频率的问题,提高了故障诊断的准确率。黄华等^[22]提出了一种将小波包变换与图论诊断法结合的故障诊断方法,用图论诊断法缩小数控机床进给系统故障的

可能范围,之后用小波包提取故障特征,从而完成故障的判别。郑海波^[23]等针对齿轮故障提出了一种时间平均小波谱的概念,在经过连续小波变化后,通过谱形比较以及特征能量判断齿轮的故障。另一种方法是基于机器学习的方法^[24],这种方法直接将观测到的数据与故障建立映射关系,有着不用考虑信号处理机理的优势,对复杂环境、复杂系统的故障诊断提供了一种更有效的处理方法,并且基于机器学习的方法还可以同信号处理等方法相结合,进一步提高故障诊断的准确率。

当今已经有许多学者对基于机器学习的故障诊断方法进行了研究,并且电机与轴承作为重要的驱动装置已经成为这一类故障诊断方法的研究目标^[25, 26]。Hinton 等提出了深度信念网络(DBN)这一概率生成模型^[27],而赵光权等^[28]采用 DBN 网络从轴承振动的原始数据信号中提取故障特征,主要通过组合低层网络数据形成高层的特征,有效地解决了传统依靠专家经验知识进行判别的问题,该方法提高了诊断的精度。ONEL 等^[29]基于 RBF 神经网络提出了一种轴承故障诊断模型,实验证明了该模型的有效性。张淑清等^[30]将双树复小波与深度信念网络结合,在轴承故障诊断中取得了良好的效果。自编码及其变种也同样受到众多学者关注^[31],该模型直接从原始故障信号中提取所需特征,最后可以通过分类器进行模式识别。赵洪山^[32]等采用基于深度自编码网络和 XGBoost 的故障诊断算法对风电机组发电机进行诊断,实现故障的实时捕获,并解决了特征提取困难的问题。卷积神经网络(Convolutional Neural Networks, CNN)同样被运用到故障诊断中,INCE T^[33]等提出了基于 CNN 的实时电机故障诊断方法,该方法利用 CNN 提取特征,并结合分类算法,实现了对电机实时电流信号的特征提取和分类。Liu^[34]等将经验小波分解与 CNN 中的残差网络相结合,对电路故障进行诊断同样取得了较好的诊断效果。除此之外还有将支持向量机(Support Vector Machine, SVM)^[35]、循环神经网络(Recurrent Neural Network, RNN)等^[36, 37]运用到故障诊断中同样取得了较好的效果。

目前对于高速公路机电设备养护问题已经有学者进行了研究,然而这些研究主要集中于机电设备的养护管理^[38]、寿命预测^[39]和状态评估^[40]等方面,对于具体设备的故障诊断问题则研究较少^[41]。作为高速公路机电系统的一部分,公路隧道通风设备也存在着同样的问题^[42],但在轴承、电路以及电机等领域故障诊断方法已经有了较深入的研究,并且基于数据驱动的故障诊断有着模型易获得,检测精确度高等特点。同时公路隧道通风设备决定着公路隧道通风系统能否正常高效地运行,因此有必要进行基于数据驱动的歌

路通风设备故障诊断研究。

1.3 研究内容与章节安排

本文首先分析了公路隧道通风设备的结构,根据这种结构搭建了通风风机故障实验台;其次完成公路隧道通风设备故障的模拟并进行故障信号数据的采集与存储;然后根据所采集的故障数据完成公路隧道通风设备故障诊断模型的搭建并完成模型的验证;最后基于目前隧道机电设备管理情况,设计一种结合实时故障诊断功能的公路隧道风机监控系统。本文共分为四章,具体章节安排内容如下。

第一章,绪论。本章通过对主要研究内容以及研究背景的阐述,对公路隧道通风设备故障诊断的必要性进行了具体的分析,在总结本文研究内容的意义的同时对故障诊断的现状进行了一定程度的归纳。

第二章,公路隧道通风设备故障模拟方法研究。本章首先分析公路隧道通风设备的类别与结构以及公路隧道通风设备故障类型,其次根据主要的公路隧道通风设备结构搭建用以模拟故障的通风设备故障实验台。然后通过公路隧道通风设备故障分析确定用于故障诊断实验的故障类型,并通过通风设备故障实验台完成故障数据的采集与存储。

第三章,公路隧道通风设备故障诊断方法研究。在本章中首先论述数据预处理的方法,然后论述信号特征提取的方法和基于注意力机制的故障判别方法,最后搭建 EEMD-SE 故障诊断模型,并介绍算法模型结构与算法理论。

第四章,公路隧道通风设备故障诊断实验。本章首先对风机故障实验台所采集的数据特点进行分析,并完成故障数据的预处理;之后通过与其他几种算法的比较完成对本文所提出的 EEMD-SE 故障诊断模型的验证;最后根据隧道通风设备以及隧道的环境特点,完成结合实时故障诊断功能的公路隧道风机监控系统设计。本文的技术路线如图 1.2 所示。

由图 1.2 可以看出,本文的技术路线囊括了问题凝练、模型构建与验证研究三大部分。首先基于目前研究现状分析对本文需要研究的内容进行凝练与总结;其次结合公路隧道实际的应用场景,搭建公路隧道通风设备实验台,通过制造通风设备的不同运行状况,进行故障信号的采集;然后根据所采集的故障信号搭建公路隧道通风设备的故障诊断模型,进行故障诊断并验证模型的准确性;最后根据故障诊断方法与公路隧

道通风设备特点设计一种结合实时故障诊断功能的公路隧道风机监控系统。

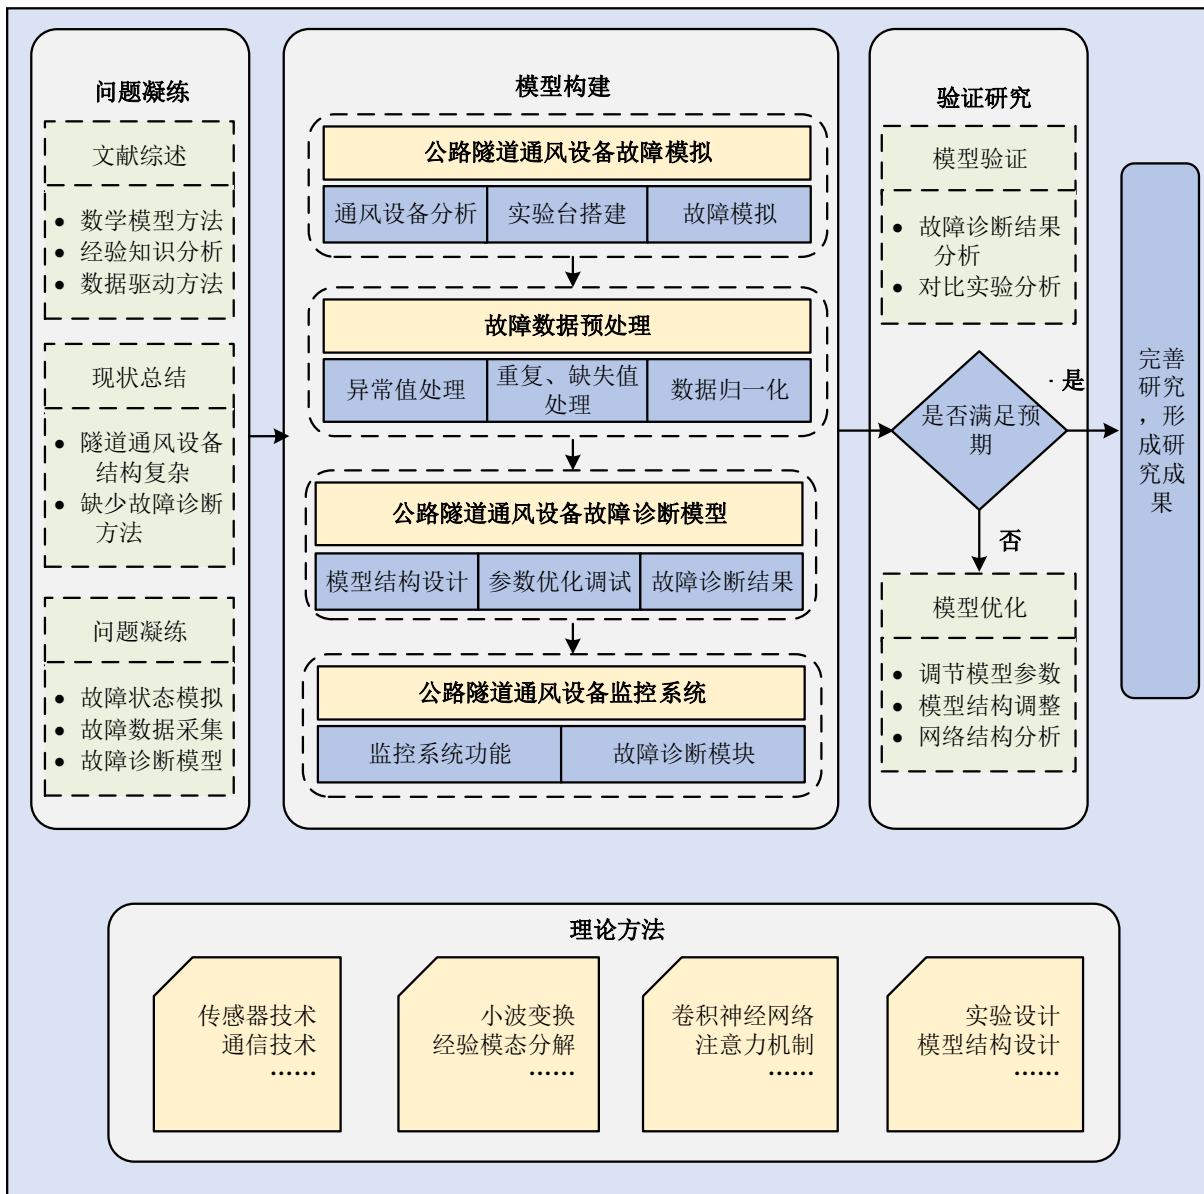


图 1.2 技术路线图

第二章 公路隧道通风设备故障模拟方法研究

本章主要完成公路隧道通风设备结构分析、公路隧道通风设备故障分析、公路隧道通风设备故障实验台的搭建、通风设备故障模拟和故障数据的采集。首先通过分析公路隧道通风设备结构完成故障实验台的设计与搭建；其次通过分析公路隧道通风设备故障确定模拟故障的类型；然后基于故障实验台完成通风设备故障的模拟，最后通过 stm32 单片机为主体的信号采集系统完成故障数据的采集、传输与存储，将故障的振动信号保存在服务器中。

2.1 公路隧道通风设备分析

2.1.1 公路隧道通风设备类别分析

公路隧道中通风设备主要为通风风机，通常根据风机的功能以及使用方式分为轴流风机和射流风机^[43]。

射流风机一般安装在公路隧道顶部，不侵入隧道建筑界限，通常用于公路隧道的纵向通风、半横向通风方式和组合通风方式中，具有噪音低，运转平稳等特点。射流风机在工作时以隧道本身作为风道，将一部分隧道中的空气由套筒入口吸入，经过叶轮加速后，由风机套筒出口喷出，从而加速隧道顶部空气流动速度，并带动整个隧道的空气同向流动。当气流速度衰减到一定程度后，由下一组射流风机以相同的工作方式继续加速隧道内的气流运动，在多组射流风机的共同作用下，将隧道内的空气从出口排出，从而达到排除隧道内污染空气的目的，射流风机通常可以和车流形成的活塞风共同作用完成隧道的通风。

射流风机的结构如图 2.1 所示，其结构主要分为风机主体部分和消音器部分。主体部分一般包括叶轮、转轴、电机和套筒，是实现射流风机正常工作的主要结构，电机用以提供风机的动力，通过转轴带动叶轮转动将套筒内的气体沿着轴线方向推送，并且随着叶轮的旋转，气体的速度会逐渐增加，从而在风机出口处产生高速高压的气流。消音器部分主要包括射流风机主体两侧的消音器结构和防护网罩，消音器结构用来降低整个射流风机的工作噪音，防护网罩则对风机有一定的保护作用。另外，部分风机还具有引流筒的结构，该部分有着增加送风效率和消音的作用。




图 2.1 射流风机结构图

轴流风机一般安装在与风道相连接的位置，通常配有风机房以提供布置轴流风机、电气设备、控制设备、其他辅助设备和设备检修的空间，并且设置有搬运通道和工作通道。轴流风机广泛应用于隧道纵向通风中的集中送入式、通风井排出式和通风井送排式通风，也适合半横向、全横向通风和组合通风方式。轴流风机的前端或后端通常设有风阀，随轴流风机的运转与停止而开启或关闭，达到通风控制的作用。轴流风机工作时，空气通过扩压器到达叶轮，经过叶轮加速加压后导入后端的扩压器，在扩压器将空气中动能进一步转换为空气压力后将空气排出，从而达到通风的目的。大部分轴流风机都配有叶片调节装置，使得叶片可以转动角度，起到适应不同工况的作用。轴流风机分为卧式和立式，在国外两种形式风机均有使用，而在国内通常使用卧式轴流风机。

轴流风机的一般结构如图 2.2 所示。风机的主体部分和射流风机相同，主要包括提供动力的电机、起传动作用的转轴、对气流加压加速的叶轮和外部的套筒。风机的主体两侧通过密封的软接管道与两个方向相反的扩压器相连接，之后加压器连接消音器以降低风机发出的噪声。




图 2.2 轴流风机结构图

2.1.2 通风风机结构分析

公路隧道中通风设备主要为通风风机，根据风机的结构可以分为离心式风机、轴流式风机、斜流式风机和横流式风机。

离心式风机^[44]广泛应用于工厂生产与日常生活中，其主要作用是通过风机做功，使得进入离心风机的空气压力增强并通过出口排出。气流首先由轴向进入风机，在叶轮的带动下随之旋转，最后沿着半径方向离开叶轮，离心风机通过这种离心作用做功，为气流提供能量。根据叶片出口的方向可以分为前向、后向和径向三种不同的离心式风机，一般情况下后向离心风机的应用较为广泛。

离心式风机的结构如图 2.3 所示。其主要结构由外部的蜗壳，蜗壳中的叶轮和一般处于蜗壳外部的电机构成。电机为叶轮提供动力，空气经过叶轮前方的进气口进入蜗壳，经过叶轮做功在蜗壳内加压，之后通过出风口排出。进风口有时会配有导风圈结构，以达到使空气更多向叶轮部分流动的目的。




图 2.3 离心式风机结构图

轴流式风机^[45]的气流流向与叶轮轴是同向的，气流从进风口进入后，经过叶轮做功，提高速度和压力后，沿着轴向从出风口排出。轴流风机的一般结构如图 2.4 所示，主要包括叶轮、机壳以及电机等结构。小型的轴流式风机直径只有 10cm 左右，大型的轴流式风机叶轮直径可达 20m 以上，不论是日常生活、工业生产，还是土建施工、交通运营，轴流式风机广泛应用于各种各样的场景之中。




图 2.4 轴流式风机结构图

斜流式风机^[46]（混流式风机）是一种介于离心式风机与轴流式风机结构之间的新型风机，气流在斜流式风机中，其运动方向与轴线成某一角度，具有强烈的三维特性。斜流式风机的主要结构包括叶轮、扩压器和蜗壳等部分，大多数斜流式风机的叶轮轮毂形状为圆锥形，并且斜流式风机的叶片呈三元扭曲形状，这些使得风机中的气流既有轴向运动又有离心运动。斜流式通风机的结构主要基于离心式延长和基于轴流式延长，因此斜流式风机的结构有后置蜗壳斜流式风机和后置导叶斜流式风机。

横流式风机^[47]（贯流风机）主要由电机、机壳以及叶轮等部分构成，其中叶轮通常为长筒状、多叶式，叶片为多翼前向。风机工作时，气流以叶轮敞开处为进风口，经过叶轮做功并穿过叶轮，从另一侧的出风口排出。横流式风机的轴向宽度可以依据设计需求调整，并且不影响气流的运动状态。横流式风机通常尺寸较小，出口通常窄而长，因此适合使用在扁平形的设备中以达到冷却或通风的目的。如在家用空调内机部分和电子机械的冷却方面横流式风机应用较为广泛。

在公路隧道场景下，通风风机大多数为安装在隧道顶部的射流风机和与风道相连接的轴流风机，这两种风机的气流流向与叶轮轴都是同向的，气流都是从进风口进入后，经过叶轮做功，提高速度和压力后，沿着轴向从出风口排出，所以这两种风机从结构上分析都属于轴流式风机。因此，对于公路隧道隧道通风设备的研究应该主要针对轴流式风机，故障实验台的搭建也以轴流式风机为主。

2.1.3 公路隧道通风风机故障分析

公路隧道通风风机主要为轴流风机与射流风机，这两种风机在结构上都属于轴流式风机，因此轴流风机与射流风机故障类型相似。公路隧道通风风机故障分类如图 2.5 所示。

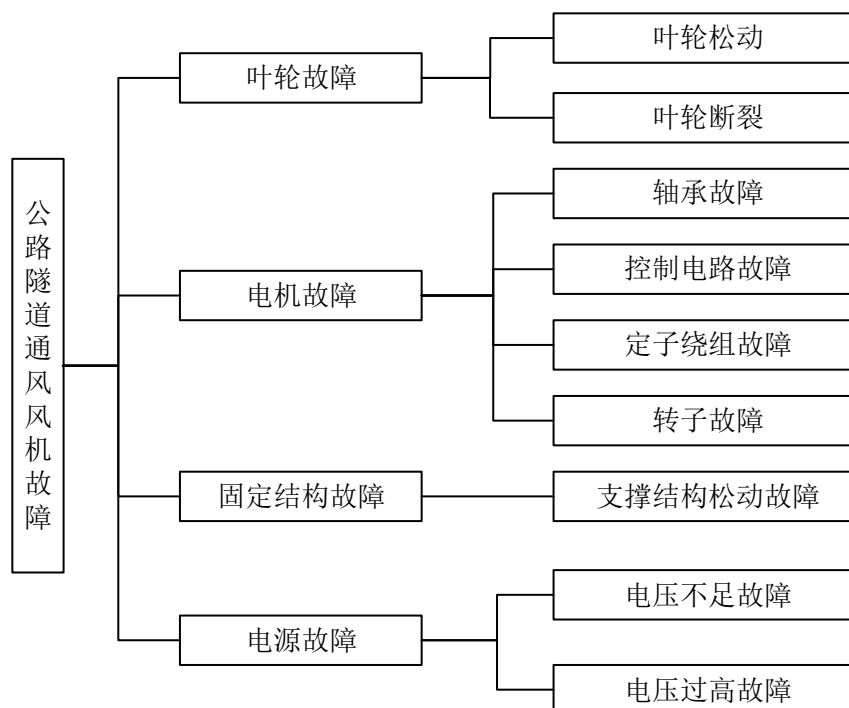


图 2.5 公路隧道通风风机故障分类图

由图 2.5 可得，公路隧道通风风机故障可以分为四类，分别为叶轮故障、电机故障、固定结构故障和电源故障。

叶轮故障可以分为叶轮松动故障和叶轮断裂故障，造成叶轮松动故障的原因可能是叶轮设计不合理，制造或安装过程中出现问题，高速旋转情况下的长期使用的磨损或者受到车辆剐蹭等外力的冲击。叶轮断裂故障出现的原因同样可能是风机在高速运转时受到了车辆剐蹭等外力的冲击，或者是因为生产制造缺陷，发生了断裂的现象。

电机故障可以分为轴承故障、控制电路故障、定子绕组故障以及转子故障。轴承故障包括轴承故障主要包括轴承磨损、过热和损坏，这类故障产生的原因是生产质量问题和长时间运行产生的磨损问题等。控制电路故障的原因主要包括安装时的接线问题、接线松动、接触不良和绝缘老化等问题。定子绕组故障主要包括定子绕组断路、短路问题，其故障产生的原因同样主要为线路老化问题。转子作为电机将电能转化为动能的重要部分，在电机的运行中起着关键的作用。转子故障主要包括转子偏心故障与转子断条故障，其中转子断条故障在频繁启动的电机中出现较多。

公路隧道通风风机的固定结构尤其是安装在隧道顶部的射流风机支撑结构对隧道的安全通行有着巨大的影响，若出现射流风机支撑结构故障，则很可能造成人员伤亡和

财产损失。支撑结构的故障主要表现为结构松动，通常通过拉拔试验进行检测。

公路隧道通风风机电源供电同样决定着风机能否正常运行，电源故障通常表现为电压不稳，从而造成电压不足或者电压过高的故障。

通过对公路隧道通风风机故障的分析，可以将故障分为轮故障、电机故障、固定结构故障和电源故障四类，因此在进行故障模拟时应当包括这四种故障。

2.2 公路隧道通风设备故障模拟方法

2.2.1 通风风机实验台结构

所搭建的风机实验台结构如图 2.6 所示。

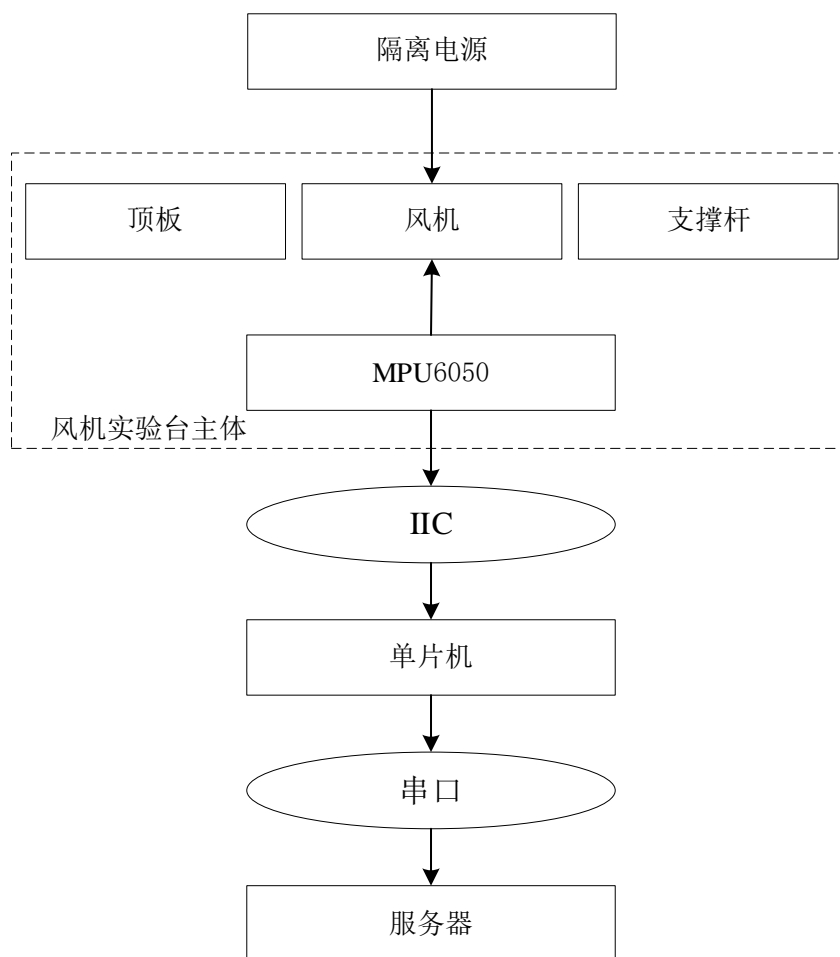


图 2.6 风机实验台结构图

由图 2.6 可得，实验台主要由 3 部分构成，分别为风机实验台主体、隔离电源和服务器^[48]。隔离电源的作用不只是为风机实验台供电，由于风机实验台的主要功能为模拟故障，为了避免故障对电源的影响，以及考虑整个实验室的用电安全，使用隔离电源将风机实验台的供电与实验室整体供电隔离，这样使得实验台发生短路等电气故障时对整

个实验室的影响较小；隔离电源还可以调节和稳定电压，从而可以完成不同电压下风机运动状态的采集；最后，隔离电源在短路等突发电气故障时可以及时断电，起到保护风机实验台主体的重要作用。

风机实验台主体的结构如图 2.7 所示。主要包括顶板、支撑顶板的支撑杆、固定风机并使风机悬挂的固定件、采集振动信号的 MPU6050 传感器以及一台小型轴流式风机。轴流风机主要有外部筒状的机壳、交流电机、转轴以及叶轮等结构，在风机实验台中所使用的风机正常工作电压为 220v，正常转速为 1450r/min。传感器使用 MPU6050，安装在小型轴流风机的电机外侧，采集三个维度的角加速度和加速度数据以达到采样振动信号的目的，传感器通过单片机驱动并保存和初步处理数据，传感器与单片机之间采用 IIC 通信。该部分的主要作用是模拟风机在公路隧道场景下会出现的故障，并采集不同故障状态下风机的加速度与角加速度信号。




图 2.7 风机实验台主体结构图

单片机选用 STM32F407，其主频较高，可以满足较高的振动采样率并向服务器实时传输较大量数据的需求。单片机通过 IIC 驱动传感器并采集数据后，通过串口 RS232 完成与服务器的通信。

服务器选择普通的 PC 即可，通过 USB 完成与单片机的 RS232 串口通信，接收实时传送的三维角加速度和三维加速度信号，并将接收到的信息以 txt 格式保存，以便后续的数据处理。风机实验台的实物图片如图 2.8 所示。



图 2.8 风机实验台实物图

2.2.2 通风风机故障模拟方案

轴流式风机的关键结构包括提供动力的电机、加速气流流动的叶轮和固定外部套筒的固定结构。电机与叶轮直接关系到风机的通风效果和安全性，如果电机不能正常工作，风机可能会运行不稳定或停止工作，从而浪费能源，增加运行成本。而叶轮的状态也决定了风机通风质量，及时发现叶轮故障可以避免风机受到更严重的故障而造成财产损失，同时叶轮故障会对隧道通行车辆带来安全隐患。因此选择电机常见的定子断条故障和叶轮的松动故障进行模拟。

外部套筒固定问题在射流风机的使用中尤为重要，在隧道顶部射流风机的安装时，为保证射流风机固定的稳定性，需要进行拉拔试验。因此选择射流风机安装方式下的固定件松动故障进行模拟。除此之外，公路隧道风机的供电直接决定了风机能否正常运行，因此同样需要对电压不足的情况进行模拟。所以选择风机实验台主要完成对正常运行、叶轮松动、转子断条、电压不足以及固定件松动状态的振动信号采集，并且这四种状态也分别代表叶轮故障、电机故障、固定结构故障和电源故障四类故障。由于车辆通行所引起的振动较为复杂，实验中较难模拟，并且通过有限元分析，小汽车通过路面时，路中的振动加速度为 250gal 左右，而路侧振动则衰减为 20gal，衰减情况较为严重，可以认为振动到达隧道顶部衰减更为明显，因此可以认为车辆通行所带来的振动对故障信号影响较小，在实验中暂时不考虑车辆所产生的振动。

（1）正常运行状态

故障诊断的重要目的是判断设备是否正常运转，因此需要采集风机正常运行状态的信息，该状态下风机供电为标准的工作电压 220v，风机处于正常运行。

（2）叶轮松动状态

叶轮作为风机结构中最重要结构之一，对通风的效果有着直接的影响，因此需要判断叶轮状态，而叶轮松动是一种常见的故障。对该状态进行模拟时，风机供电为标准的工作电压 220v，风机的叶轮固定螺丝处于松动的状态，风机其他情况正常，具体情况如图 2.9 所示。




图 2.9 叶轮松动状态图

（3）转子断条状态

转子断条是一种常见的电机故障，这种故障可以使转子电阻增大从而导致转子损耗增大，降低电机效率，甚至引起电机发热烧蚀。电机作为风机最重要的组成部分之一，为风机的通风提供动力，其故障直接影响风机的运行，因此需要对该种情况进行模拟。该状态下风机供电为标准的工作电压 220v，风机的转子人为制造断条状态，风机其他情况正常，具体情况如图 2.10 所示。




图 2.10 转子断条状态图

（4）电压不足状态

风机的供电直接影响着风机的运行状态，一般情况下为隧道通风设备供电的电网不会存在供电不稳的情况，但是不排除有特殊情况造成电网波动或配电系统故障导致风机电压不足，并且近年来新能源供能也是一大热点，在使用新的供能方式时需要对电压故障进行防范。这种状态模拟时，风机供电电压为 150v，风机其他情况正常，具体情况如图 2.11 所示。



图 2.11 供电不足状态图

（5）固定件松动状态

固定件松动这种故障主要针对悬挂在隧道顶端的射流风机，由于其特殊的安装方式，存在设备掉落的隐患。在安装射流风机时，往往要进行拉拔试验，这说明风机的悬挂稳定性非常值得重视，因此选择对风机固定件松动状态进行模拟，这种状态下风机供电为标准的工作电压 220v，风机的固定件处于松动状态，风机其他情况正常，具体情况如图 2.12 所示。



图 2.12 固定件松动状态图

2.3 风机实验台故障数据采集方法

2.3.1 风机故障采样传感器

风机故障实验台使用 MPU6050 传感器进行信号的采集, MPU6050 是一个 6 轴运动信号采集传感器, 包含了 3 轴加速度计、3 轴陀螺仪和数字运动处理引擎。并且 MPU6050 还集成有第三方数字传感器接口, 通常用于连接 3 轴的磁力计, 接口使用 IIC 通信协议。当 MPU6050 接入第三方传感器时, 可以通过主 IIC 接口向处理器传输 9 轴融合数据。在采集风机故障信号时, 重点需要关注的是风机的振动数据, 因此 MPU6050 中 3 轴加速度计和 3 轴陀螺仪采集到的加速度数据和角加速度就较为重要, MPU6050 传感器如图 2.13 所示。



图 2.13 MPU6050 实物图

MPU6050 对应的端口功能见表 2.1。在风机的故障信息采集过程中, 不需要外接 3 轴磁力计, IIC 地址可以悬空默认为 0X68, 并且不需要使用 MPU6050 的中断, 因此只需要使用前四个端口即 VCC、GND、SCL 和 SDA。

表 2.1 MPU6050 端口功能

接口名称	功能
VCC	电源
GND	接地
SCL	主 IIC 时钟
SDA	主 IIC 数据
XDA	辅助 IIC 数据
XCL	辅助 IIC 时钟
AD0	IIC 地址设置 (悬空或接地为 0X68, 接 VCC 为 0X69)
INT	中断

MPU6050 的 3 轴 (x 轴, y 轴, z 轴) 加速度计的测量范围可以通过配置寄存器来设定, 可以设定为 $\pm 2g$ 、 $\pm 4g$ 、 $\pm 8g$ 、 $\pm 16g$, 其中 g 表示重力加速度。每一轴的数值通过

两个 8 位寄存器保存 16 位带符号整数, 即取值范围为-32768—+32767, 以加速度计 x 轴为例, 其实际分辨率计算为

$$accx = p \frac{R_{accx}}{32767} \quad (2.1)$$

其中, $accx$ 为 x 轴实际的加速度, p 为设置的测量范围, 可以设置为 $\pm 2g$ 、 $\pm 4g$ 、 $\pm 8g$ 、 $\pm 16g$, R_{accx} 表示寄存器中存储值。

MPU6050 的 3 轴陀螺仪同样可以通过配置寄存器设置测量范围, 可以设定为 $250^\circ/s$ 、 $500^\circ/s$ 、 $1000^\circ/s$ 、 $2000^\circ/s$ 。每一轴的数值同样通过两个 8 位寄存器保存 16 位带符号整数, 取值范围为-32768—+32767 以陀螺仪 x 轴为例, 其实际分辨率计算公式为

$$gyrox = q \frac{R_{gyrox}}{32767} \quad (2.2)$$

其中 $gyrox$ 表示 x 轴陀螺仪实际数值, q 为测量范围, R_{gyrox} 表示寄存器中存储值。

根据式 2.1 和式 2.2 可以看出, 加速度仪和陀螺仪的取值范围设置越大, 其分辨率就越低, 而风机的振动属于较小的位移。因此应设置较小的量程, 这样既能保证所测量的结果不超出量程, 又可以得到较高的精度。

MPU6050 的 3 轴加速度计和 3 轴陀螺仪数据根据方向分为正负两种, 具体方向如图 2.14 所示。




图 2.14 加速度计与陀螺仪方向

由图 2.14 可以看出, 加速度计的 3 轴正方向分别位于芯片封装的三个面, 构成了空间直角坐标系。3 轴陀螺仪的角加速度方向绕加速度计构成的坐标系旋转, 每一轴的正方向规定为, 从原点向坐标轴正方向延伸, 顺时针为正方向, 逆时针为负方向。

通常为了保证时钟精度, 时钟源设置 x 轴作为参考, 同时关闭中断, 关闭辅助 IIC

通道和关闭 FIFO 存储等不需要的功能。陀螺仪的输出频率可以达到 8000Hz，而加速度计的输出频率较低，为 1000Hz，因此整体采样率最大为 1000Hz。由于程序运行以及信号传输等原因造成时延，采样系统实际采样率大约为 720Hz。故障实验台所使用风机的转速为 1450r/min，约为 24r/s，可以认为风机旋转的频率大约为 24Hz，因此采样系统的采样率远大于风机旋转的频率，可以采集到有效的周期信号。

MPU6050 整体特性参数见表 2.2。

表 2.2 MPU6050 特性参数

参数	说明
芯片名称	MPU6050
供电	电源 3.3-5V
通信方式	标准 IIC 协议，支持最高时钟频率为 400KHz
测量维度	3 维加速度，3 维陀螺仪
加速度计测量范围	$\pm 2g$ 、 $\pm 4g$ 、 $\pm 8g$ 、 $\pm 16g$
陀螺仪测量范围	$250^{\circ}/s$ 、 $500^{\circ}/s$ 、 $1000^{\circ}/s$ 、 $2000^{\circ}/s$
加速度计测量精度	0.1g
陀螺仪测量精度	0.1 $^{\circ}/s$
工作温度	-40-+85 $^{\circ}C$
电流（工作电压 3.3V）	500 μA -3.9mA

2.3.2 风机故障实验台通信

风机故障实验台的通信分为两部分，一部分是 stm32 单片机与 MPU6050 传感器之间的 IIC 通信，另一部分是 stm32 单片机与服务器之间的 RS232 串口通信。单片机通过 IIC 通信完成对 MPU6050 传感器的初始化、参数配置以及故障信号的数据传输；通过 RS232 串口通信将得到的故障信号传输到服务器完成数据保存。

（1）IIC 通信

传感器与单片机之间的通信采用标准 IIC 通信，IIC 通信是一种半双工同步串行通信方式，其通信线路有两条，一条为时钟线 (SCL)，另一条为数据线 (SDA)，通常 IIC 通信设备都接在 SCL 总线和 SDA 总线上，通过设备地址选择通信目标^[49]。除此之外互相通信的设备需要共同接地，并且两条线路需要接上拉电阻。IIC 通信结构图和通信时序图如图 2.15 和图 2.16 所示。

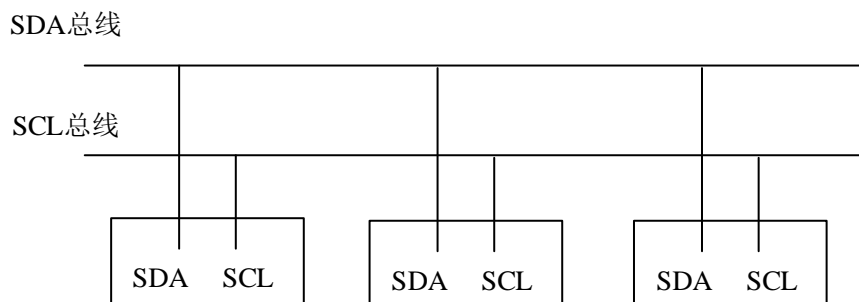


图 2.15 IIC 通信结构图




图 2.16 IIC 通信时序图

IIC 通信过程如下：

- 1) 当线路空闲不传输数据时，SDA 与 SCL 被拉高，都为高电平；
- 2) 当设备准备进行信息传输时，保持 SCL 总线高电平并将 SDA 总线拉低，这一信号称为起始信号。一般为了保证信号的准确，在 SDA 拉低 $4.7\mu\text{s}$ 后，SCL 与 SDA 再开始下一步动作；
- 3) SCL 开始输出时钟信号，SDA 传输数据时，在 SCL 为低电平时发生变化而在 SCL 为高电平时保持电平不变，从而实现数据的同步传输，即在 SCL 低电平时确定 SDA 传输的一位数据（高电平 1，低电平 0），之后拉高 SCL，并保持一段时间（一般为 $4\mu\text{s}$ ），然后就拉低 SCL 完成这一位数据的传输。之后输入 SDA 下一位数据的值并重复这一过程；
- 4) 发送端传输完一个字节即八位数据后，会释放 SDA 总线，等待接收端的 ACK 应答信号，这时候若接收端将 SDA 置 0（拉低电平），则表示应答，若接收端 SDA 输出 1 则非应答；
- 5) 发送端继续传输下一个字节的信号并在结尾等待应答，即重复第 3) 步和第 4) 步；

6) 当发送端发送完信息后, 会发出停止信号, 表示信号暂时传输结束, 即在 SCL 高电平时, SDA 产生从低电平到高电平的上升沿。具体做法是将 SCL 与 SDA 置 0 (拉低电平) 并持续并保持一段时间 (一般为 $4\mu\text{s}$), 然后将 SCL 置 1 再将 SDA 置 1 (拉高电平) 并持续 $4\mu\text{s}$ 。

(2) RS232 串口通信

RS232 串口通信是一种全双工的异步串行通信标准, 也是目前最常用的串行通信标准之一, 通常由 25 个引脚或 9 个引脚组成, 但是要完成通讯, 只需要两根数据线、一根接地线和一根电源线就可以实现功能^[50]。与 IIC 通过时钟线信号解析数据线传输信号不同, RS232 通过设定发送端与接收端码元时间长度, 从而实现信息解析, 通常将单位时间内传输的码元个数称为波特率, 接收端和发送端通信时要求波特率必须相同。RS232 标准没有时钟线, 有两条数据线, 发送设备的输出端口 (TXD) 与接收设备的输入端口 (RXD) 相连; 发送设备的 RXD 则与接收设备 TXD, 实现全双工通信。

RS232 的电气特性如下:

- 1) RS232 串口通信一般要求在 15m 以内;
- 2) RS232 为全双工通讯, 支持同时双向传输;
- 3) 逻辑 1: $-3 \sim -15\text{V}$, 逻辑 0: $+3 \sim +15\text{V}$ 。

在风机故障实验台中, RS232 主要作用是完成单片机与服务器之间的传输, 其传输距离可以满足需求。在故障采集系统中, RS232 只需要完成从单片机到服务器的单向数据传输, RS232 通信的时序图如图 2.17 所示。




图 2.17 RS232 通信时序图

数据包由单片机的 TXD 端口发送到服务器的 RXD 端口, 一般 RS232 数据帧包括起始位、数据位、校验位和停止位, RS232 的具体传输过程包括设置波特率、设置校验

位、设置停止位长度、设置数据位和数据传输。

1) 设置波特率

RS232 没有时钟线,传输前单片机与服务器需要设定相同的波特率,即设定码元长度从而实现信号的解析,图 2.17 中虚线间隔表示一个码元长度,风机故障实验台为了提高采样率,采用的波特率为 1000000。

2) 设置校验位

传输信号时可能会出现干扰而导致数据传输出错,为了验证传输的数据是否正确,在传输开始前,单片机与服务器需要约定使用校验位的方式,校验位一般有奇校验、偶校验、“1”校验、“0”校验和不设置校验位。

奇校验的内容是,若数据位中“1”的个数为奇数则校验位为 1,若数据位中“1”的个数不为奇数则校验位为 0。如 8 位数据位中有 5 个“1”,则发送端校验位为 1,这时若接收端得到数据位中的“1”的个数是奇数,并且符合校验位的“1”,则认为传输正确,若接收端得到数据位中的“1”的个数是偶数,则不符合校验位的“1”,认为传输出错。

偶校验与奇校验过程相似,但校验位设置相反。偶校验的内容为,若数据位中“1”的个数为偶数则校验位为 1,若数据位中“1”的个数不为偶数则校验位为 0。接收端的校验过程与奇校验相同,同样是判断校验位与数据位中“1”的个数是否一致。

“1”校验的内容较为简单,是发送端直接将校验位设置为 1,接收端只需判断校验位是否为 1,若为 1 则认为数据传输正常,若为 0 则认为传输出错。

“0”校验内容与“1”校验内容相似,发送端直接将校验位设置为 0,接收端判断校验位是否为 0,若为 0 则认为数据传输正常,若为 1 则认为传输出错。

另外,接收端与发送端可以约定不使用校验,这样数据帧中就不包含校验位了。

3) 设置停止位长度

停止位用高电平“1”来表示,其的长度一般为 1 位,也可以设置为其他长度,只需通信双方同时设置即可。

4) 设置数据位

数据位包含了传输的所有信息,同时可以根据传输数据长度而设置数据位,一般根据需求设置为 7 位或 8 位。

5) 数据传输

RS232 数据传输帧为一个低电平数据位起始位, 之后传输数据位, 在风机故障实验台中设定为 8 位数据位, 其次传输 1 位奇校验位, 因此 8 位数据位后传输 1 位奇校验位和 3 位停止位, 之后开始下一个数据的传输。

(3) 故障数据采集流程

在风机故障实验台中, 使用 stm32 单片机进行数据采集系统的控制, 其工作流程如下:

1) 初始化 IIC 通信, 包括初始化 SDA 与 SCL 所使用的 GPIO 端口, 开启 IIC 端口时钟和配置 IIC 通信时钟频率, 这时单片机的 SDA 与 SCL 对应的 GPIO 端口为输出模式;

2) 初始化用以 RS232 通信的 USART 端口, 包括设置初始化 GPIO 端口, 使能 USART 时钟和完成波特率、数据位数停止位长度以及奇偶校验方式的配置。

3) 单片机发起信息传输并传输一个字节, 包括 7 位地址信息和 1 位表示写入的传输方向信息, 发送后单片机会将 SDA 端口设置为输入模式用以接收 ACK 应答信号, 并在接收到应答信号后设置 SDA 端口为输出模式;

4) 通过 IIC 通信 MPU6050 不同寄存器写入配置信息, 包括陀螺仪和加速度计的量程、采样率, 然后关闭 FIFO、传感器的中断和传感器的 IIC 主模式;

5) 通过 IIC 读取 MPU6050 的地址信息, 若地址正确则向设置传感器时钟以 x 轴为参考, 并写入陀螺仪和加速度计工作的指令。

6) 读取 MPU6050 传输的陀螺仪和加速度计数据, 然后封装为 RS232 要求格式的数据帧, 通过 RS232 向完成波特率等设置的服务器传输数据并完成数据的存储。

7) 重复第 5) 和第 6) 步, 完成故障数据的采集与存储。

2.4 本章小结

本章首先分析了公路隧道通风设备的主要类型以及风机的种类, 通过分析可以看出公路隧道中主要使用的轴流风机和射流风机在结构上都属于轴流式风机。其次分析了公路隧道通风风机的故障类型, 并将故障类型分为叶轮故障、电机故障、固定结构故障和电源故障 4 类。然后基于公路隧道通风设备结构搭建了轴流式风机结构的风机故障实验

台，并根据 4 种故障类型，选取正常运行、叶轮松动、转子断条、电压不足和固定件松动状态进行模拟。最后实现了基于 stm32 单片机的故障数据采集系统，完成了故障数据的采集、传输与存储功能。本章所搭建的风机故障实验台为第三章通风设备故障诊断算法的研究提供了数据支撑。

第三章 公路隧道通风设备故障诊断方法研究

本章主要完成基于第二章故障实验台采集数据的公路隧道通风设备故障诊断算法实现。首先论述所采集的振动数据预处理方法,之后完成本文提出的基于集合经验模态分解与通道注意力机制的公路隧道通风设备故障诊断模型 (EEMD-SE) 搭建。

3.1 故障数据预处理方法

3.1.1 异常值处理方法

风机实验台采集的原始数据为六维的振动数据,包括三维加速度数据和三维角加速度数据,这些数据往往因为外界的干扰或信号的传输异常而产生少量的异常值^[51]。虽然异常值相较于整个采样数据数量较少,但是对于故障信号的特征提取以及故障诊断模型的训练等都有着较大的影响,容易造成故障诊断模型精度下降的问题。因此在使用故障诊断模型前,应当对这些干扰进行处理。

异常值可以分为数据结构异常和数值异常,数据结构异常值表现为数据的缺失和数据的连续重复,此类的异常值可以直接进行删除处理,数值异常的异常值处理方法则通常有 3σ 检验法和箱线图法。

(1) 3σ 检验法

3σ 检验法一般用于正态分布或者类似正态分布的数据中,在此类的数据上处理效果较好。 3σ 检验法首先计算待处理数据的均值 μ 和标准差 σ ,之后比较每一个数据与均值 μ 的差值。若差值的绝对值小于 3 倍的标准差 (3σ) 则认为该数据是正常值,若差值的绝对值大于 3 倍的标准差 (3σ) 则认为数据是异常值,应当作删除处理。 3σ 检验法异常值判断公式为

$$x_n \notin (\mu - 3\sigma, \mu + 3\sigma) \quad (3.1)$$

其中, μ 为待处理数据的均值, x_n 为第 n 个待处理数据, σ 为待处理数据的标准差。

分别对整个待处理数据样本中的所有个体进行判断后,将所有的异常值并删除,可以认为得到的数据中基本不含有异常值。

(2) 箱线图法

对于故障实验台所采集的原始数据,数值异常的异常值很大一部分是因为传输出错

导致的，这样的数据与正常数据相比往往数量级差距很大。因此在处理异常值时，箱线图更适合处理这样的数据。

箱线图 (Box plot) 也称作箱须图 (Box-whisker Plot)，可以用来反映一组或多组数据分布的中心位置和散布范围。将待处理数据按照从小到大的顺序排列后，将数据分为四部分，而将数据分为四部分的数称为四分位数。其中，从小到大分别为下四分位数 (Q_1)，中位数 (Q_2) 和上四分位数 (Q_3)，分别表示从小到大排列后 25%、50% 和 75% 的数字。在箱线图中，正中间的线表示数据的中位数 (Q_2)，箱子的上下边分别表示数据的上四分位数 (Q_3) 和下四分位数 (Q_1)，即箱子包含了中位数周围 50% 的数据，所以箱子的高度在一定程度上可以反映数据的离散程度。上四分位数 (Q_3) 和下四分位数 (Q_1) 的差值称为四分位距 (IQR)，这样确定了箱子的大小后就可以计算箱线图的上下界，其计算公式为

$$Q_m = Q_3 + 2 \times IQR \quad (3.2)$$

$$Q_n = Q_1 - 2 \times IQR \quad (3.3)$$

其中， Q_m 表示箱线图的上界， Q_n 表示箱线图的下界， Q_1 为下四分位数， Q_3 为上四分位数， IQR 为四分位距，箱线图如图 3.1 所示。




图 3.1 箱线图示例图

计算得到的上下界可以认为是这组数据正常值的最大最小值，因此上下界外的点可

以认为是异常值。一般箱线图计算上下界时 IQR 前的系数取 1.5，但是要最大程度保证数据的连续性，同时由于需要处理的异常值大多数是由于传输或采样错误导致的，其特征为数据远大于或远小于正常数据，因此本文 IQR 前的系数进行适当放大取 2。对于上下界外的异常值需要进行删除操作。

3.1.2 数据标准化方法

故障实验台所采集的故障振动信号包含角加速度和加速度两种数据，不仅存在不同的量纲，而且数值差距也较大，加速度数据与角加速度数据相比数值上甚至可以相差两个数量级^[52]。如果直接进行神经网络的学习，这样有可能会角加速度数据大小与加速度数据的噪声数值大小相同，就有可能出现维度缺失，忽略了角加速度数据所包含的特征。并且后续的经验模态分解需要输入信号局部极大值极小值构成的上下包络线尽量关于 x 轴对称。因此，在对于这种数据进行数据分析前，需要对其进行标准化，使得后续模型的输入在同一个数量级，并满足后续输入的要求，从而达到提高模型精度的目的。数据标准化常见的方法有 Z-score 标准化和 min-max 标准化。

Z-score 标准化方法首先计算数据的均值和标准差，对每一个数据与均值作差后除以数据的标准差，使得处理后的数据近似符合标准差为 1，均值为 0 的标准正态分布，计算公式为

$$x' = \frac{x - \mu}{\sigma} \quad (3.4)$$

其中， x' 为处理后的数据， x 为原始数据， μ 为原始数据均值， σ 为原始数据标准差。

Z-score 标准化虽然计算简单，应用广泛，在数据符合正态分布时效果较好，但是对于非正态分布的数据效果较差，故障信号数据在某些状态下可能不符合正态分布，因此选择 min-max 标准化更为合适。

min-max 标准化是通过对原始数据进行线性变换，一般将数据序列结果映射在 [0,1] 之间。由于后续的经验模态分解需要输入信号局部极大值极小值构成的上下包络线尽量对称，因此将数据序列结果映射在 [-1,1] 之间，计算公式为

$$x' = 2 \times \left(\frac{x - x_{\min}}{x_{\max} - x_{\min}} \right) - 1 \quad (3.5)$$

其中， x_{\max} 为样本数据中的最大值； x_{\min} 为样本数据中的最小值。

3.2 故障信号特征提取方法

3.2.1 小波变换

傅里叶变换^[53]可以将一个连续信号分解为一组不同频率的三角函数信号，不同频率的三角函数组成正交基就可以线性组合拟合原始信号。但是由于三角函数在时域是一个无限的信号，因此作为正交基去拟合原始信号时会出现以下问题。首先，对于突变的信号需要大量的三角函数组成的正交基去拟合；并且，原始信号进行傅里叶变换时，只能获得其频域信息，无法获得时域信息，即不能获得这些不同频率的信号分量在时域上出现的具体位置。这导致了傅里叶变换在处理非平稳信号时效果较差。为了解决这一问题，将整个信号分为若干个窗口后再进行傅里叶变换的短时傅里叶变换 (STFT) 就被提出了。短时傅里叶变换将整个信号在时域上通过窗口划分为若干个部分，这样每一个部分可以看作平稳信号，并且可以一定程度上反应时域信息，但是窗口大小的选取较为困难，窗口过大则时域分辨率低，窗口过小则信号较短，从而导致频域分辨率较低，小波变换则一定程度可以解决这些问题。

小波变换^[54]是一种常见的信号处理方法，其延续了短时傅里叶变换的思想，处理信号既保留了时域信息又得到了频域信息。小波变换用时域上有限长的会衰减的小波基替换了时域上无限长的三角函数基，这样既可以表示时域、频域信息，同时时域、频域窗口也是可调的。小波变换在信号的高频部分采用时域窄窗口和频域低分辨率，而在低频部分则采用时域的宽窗口和频域的高分辨率。小波变换通过平移与伸缩基本小波函数来获得小波序列，通过调整平移获取时域信息，通过调整伸缩获取频域信息。

函数 $\psi(t)$ 属于平方可积函数空间 $L^2(R)$ ，即函数 $\psi(t)$ 满足公式

$$\psi(t) \in L^2(R) \quad (3.6)$$

并且函数 $\psi(t)$ 的傅里叶变换满足公式

$$C_\psi = \int_{-\infty}^{+\infty} \frac{|\varphi(\omega)|^2}{\omega} d\omega < \infty \quad (3.7)$$

则称函数 $\psi(t)$ 为基本小波函数。其中， $\varphi(\omega)$ 为函数 $\psi(t)$ 的傅里叶变换后所得函数， C_ψ 为允许条件。

经过小波 $\psi(t)$ 伸缩和平移可得小波函数 $\psi_{a,b}(t)$ ，其公式为

$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right) \quad a, b \in R, \text{ 且 } a \neq 0 \quad (3.8)$$

其中, 每一个满足式 3.8 的函数称为小波基, a 为尺度参数代表着频域的分辨率, b 为位移参数代表着时域分辨率。

若待处理信号 $f(t)$ 是一个关于时间 t 的连续函数, 则其小波变换为

$$W_f(a, b) = \langle f, \psi_{a,b} \rangle = |a|^{-1} \int_{-\infty}^{+\infty} f(t) \overline{\psi\left(\frac{t-b}{a}\right)} dt \quad a \neq 0 \quad (3.9)$$

其中, $\overline{\psi\left(\frac{t-b}{a}\right)}$ 为 $\psi\left(\frac{t-b}{a}\right)$ 的复共轭函数, $W_f(a, b)$ 为连续小波变换后的函数。

在实际应用中, 通常使用计算机处理小波变换, 因此输入数据一般为离散的, 离散小波变换 (DWT) 应用较多。离散小波变换通过互补的高通、低通滤波器将输入信号分解为高频、低频两部分。如图 3.2 所示, 若输入信号的最高频率为 F_s , 则高通滤波器和低通滤波器将输入信号分解成频率为 $(\frac{F_s}{2}, F_s)$ 和 $(0, \frac{F_s}{2})$ 两部分, 称为半带滤波器。




图 3.2 半带滤波器示意图

若原始输入信号的采样点为 N 个, 经过高通滤波器和 $1/2$ 频率采样后会得到 $N/2$ 个点, 将这 $N/2$ 个点称为小波分解的高频系数 $H1$; 同样的, 经过低通滤波器和 $1/2$ 频率采样后也会得到 $N/2$ 个点, 称其为小波分解的低频系数 $L1$ 。这一过程称为第一层小波分解, 以同样的半带滤波器对第一层分解得到的低频部分继续进行分解, 称为第二层小波分解, 重复此过程就完成了离散小波分解, 分解过程如图 3.3 所示。




图 3.3 小波分解过程图

此时，第 j 层序列 $f_j(t)$ 的离散小波变换为

$$DWT(f_j(t)) = \left\langle f_j, \psi_{2^j, 2^j k} \right\rangle = 2^{-\frac{j}{2}} \int_{-\infty}^{+\infty} f_j(t) \overline{\psi\left(\frac{t-2^j k}{2^j}\right)} dt \quad (3.10)$$

其中 j 为第 j 层小波分解， k 为位移参数。

常用的基本小波函数有 Harr 小波以及 Morlet 小波等，选择不同的小波对于小波分解的效果影响很大，虽然小波包分解改进了小波分解只在低频部分继续分解的不足，同时能得到更精准的频带，但是仍然存在基本小波函数的选择问题，这对于不同状态下的风机振动信号的分解较为困难。

3.2.2 EMD 经验模态分解

经验模态分解 (Empirical Mode Decomposition, EMD) 是一种自适应的信号分解方法，在处理非平稳、非线性的信号时具有很好地效果^[55]，EMD 可以通过原始信号直接计算自适应的基函数，避免了基函数的选择问题。EMD 将复杂的输入信号分解为一系列符合希尔伯特变换要求的信号，这些信号按照频率排列，称为本征模态函数 (Intrinsic Mode Function, IMF)，这赋予了信号瞬时频率物理实体。因此，EMD 分解得到的本征模态函数应当是对称的，一般要求 IMF 具体满足以下条件：

(1) 函数在整个时域，其极值数量（包括极大值与极小值）与零点数量最多相差为 1。这表示每一个 IMF 的极大极小值之间必然会有一个零点，IMF 围绕坐标轴上下波动。

(2) 在 IMF 的任意时刻，待分解信号局部最大值所构成的上包络线和局部最小值

构成的下包络线的平均值为零。

该条件将经典的全局性要求变为了容易达成的局部性要求，这让全局尺度上非对称的非平稳信号更容易满足条件。该条件也可以表示为待处理信号的局部平均值为零，但是直接计算数据的局部平均值存在时间尺度上的选择问题，因此选择局部最大值所构成的上包络线和局部最小值构成的下包络线的平均值为零来表示待处理信号波形局部对称。对于输入的原始信号 $s(t)$ ，其 EMD 分解过程如图 3.4 所示。

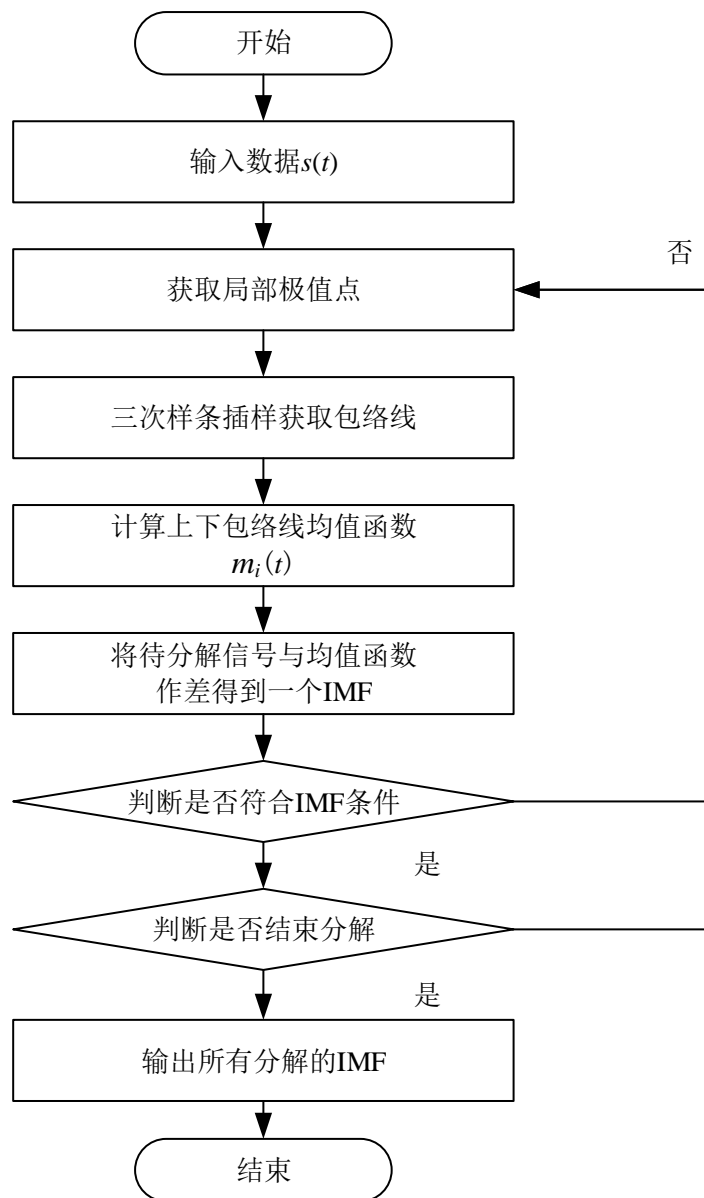


图 3.4 EMD 分解流程图

由图 3.4 可以看出，EMD 的分解步骤为如下：

- (1) 对于输入信号 $s(t)$ ，首先计算其局部极大值点与局部极小值点，并将局部最大

值与局部最小值分别进行三次样条插样，得到上包络函数 $s_{ih}(t)$ 与下包络函数 $s_{il}(t)$ 。

(2) 根据得到的上包络线和下包络线进行均值函数求解，求解方式为

$$m_i(t) = [s_{ih}(t) + s_{il}(t)] / 2 \quad (3.11)$$

其中， $m_i(t)$ 为求解第 i 个 IMF 过程中的均值函数， $s_{ih}(t)$ 与 $s_{il}(t)$ 分别为求解第 i 个 IMF 过程中得到的上包络函数和下包络函数。

(3) 根据待分解的函数与均值函数，计算 IMF，其公式为

$$imf_i(t) = L_i(t) - m_i(t) \quad (3.12)$$

其中， $imf_i(t)$ 为分解的第 i 个 IMF 函数， $L_i(t)$ 为待分解信号，在 $i = 1$ 时 $L_i(t)$ 为输入信号 $s(t)$ 。

(4) 对得到的函数进行判断，若不满足构成 IMF 的条件，则舍弃该函数并重新开始第 (1) 步；若满足构成 IMF 的条件，则认为该函数是第 i 个 IMF 函数，之后计算下一次迭代的函数，其公式为

$$L_{i+1}(t) = L_i(t) - imf_i(t) \quad (3.13)$$

(5) 判断是否满足停止分解条件，当 $L_{i+1}(t)$ 为常数或单调函数时，则认为从其中不能再分解出新的 IMF，分解应当停止。但是在实际应用当中，信号都较为复杂，若按照上述条件则较难以达成，因此往往设定新的停止条件，判别公式为

$$SD = \sum_{i=0}^T \frac{|imf_{i+1}(t) - imf_i(t)|^2}{imf_i(t)^2} \quad (3.14)$$

其中， T 为待分解信号的时间长度， $imf_{i+1}(t)$ 为第 $i+1$ 次的经验模态函数， $imf_i(t)$ 为第 i 次分解的经验模态函数， SD 为停止条件一般选择 0.2-0.3。

根据上面的分解过程，可以看出输入信号 $s(t)$ 在分解多个 IMF 后会有一部分残余，IMF 函数和残余函数可以重构输入信号，构建方法为

$$s(t) = \sum_{i=0}^n imf_i(t) + res(t) \quad (3.15)$$

其中， n 为分解得到的 IMF 个数， $res(t)$ 为残余分量。

根据 EMD 分解的过程也可以看出，EMD 会根据输入信号自适应的选择分解出的 IMF 频率，不需要人为选择，同时也不需要像小波分解一样选择基函数，并且分解出的

IMF 频率由高到低排列,并同时可以反应原始输入信号的时域和频域特征。通常可以认为,分解出的频率较高的 IMF 所包含的特征更加丰富,重要性也较高,频率较低的 IMF 信号则包含特征较少,重要性较低。因此 EMD 分解不仅可以看作一个滤波器,同时也可以作为一种成分分析的方法。

3.2.3 EEMD 集合经验模态分解

EMD 分解虽然不需要考虑选择基函数的问题,但是在处理一些含有间断信号的数据时容易产生模态混叠的问题。风机的故障信号往往容易包含这一种在很小时间间隔的小幅值高频信号。模态混叠是指在一个本征模态函数中,包含了差异极大的特征时间尺度,或者相近的特征时间尺度上分布在不同的本征模态函数中,即在一个 IMF 中包含了频率差异很大却不相同的信号,或者频率分布相似的信号却出现在不同的 IMF 中。

针对这一问题,集合经验模态分解 (Ensemble Empirical Mode Decomposition, EEMD) 通过向原始信号中添加频谱均匀分布的高斯白噪声,这样可以在分解过程中避免因为局部极值分布不均匀导致模态混叠^[56]。若是仅对加入白噪声后的输入信号进行分解,则容易出现未加入白噪声的原始输入信号本身没有包含的特征,干扰后续的处理。因此, EEMD 对原始输入信号多次加入白噪声,分别进行 EMD 分解,之后进行平均,则可以认为去除了均值为零的白噪声,保留的结果就是原始输入信号的特征。这样不但有效的处理了 EMD 的模态混叠问题,而且可以认为对原始信号基本没有影响, EEMD 的分解过程如图 3.5 所示。

EEMD 的算法步骤如下:

(1) 将 m 个不同的均值为零的高斯白噪声序列 $n_k(t)$ 加入到原始信号 $s(t)$ 中,其中 $n_k(t)$ 表示为第 k 次加入的高斯白噪声,得到新的信号,其公式为

$$s_k(t) = s(t) + n_k(t) \quad (3.16)$$

其中, $s_k(t)$ 表示第 k 个加入白噪声后的信号, $k=1,2,3,\dots,m$ 。

(2) 将加入白噪声的信号分别进行 EMD 分解,即对 $s_k(t)$ 进行 EMD 分解,其公式为

$$s_k(t) = \sum_{j=0}^n imf_{kj}(t) + res_k(t) \quad (3.17)$$

其中, $imf_{kj}(t)$ 为第 k 次加入高斯白噪声后分解得到的第 j 个 IMF 函数, $res_k(t)$ 是加入白噪声 $n_k(t)$ 后 EMD 分解得到的残余分量。

(3) 将对应的 IMF 进行总体平均, 得到最终的 IMF, 其公式为

$$imf_j(t) = \sum_{k=0}^m imf_{kj}(t) \quad j=1,2,3\dots J \quad (3.18)$$

其中, $imf_j(t)$ 表示 EEMD 分解得到的第 j 个 IMF 模态函数, J 表示 EEMD 分解得到的 IMF 函数数量。

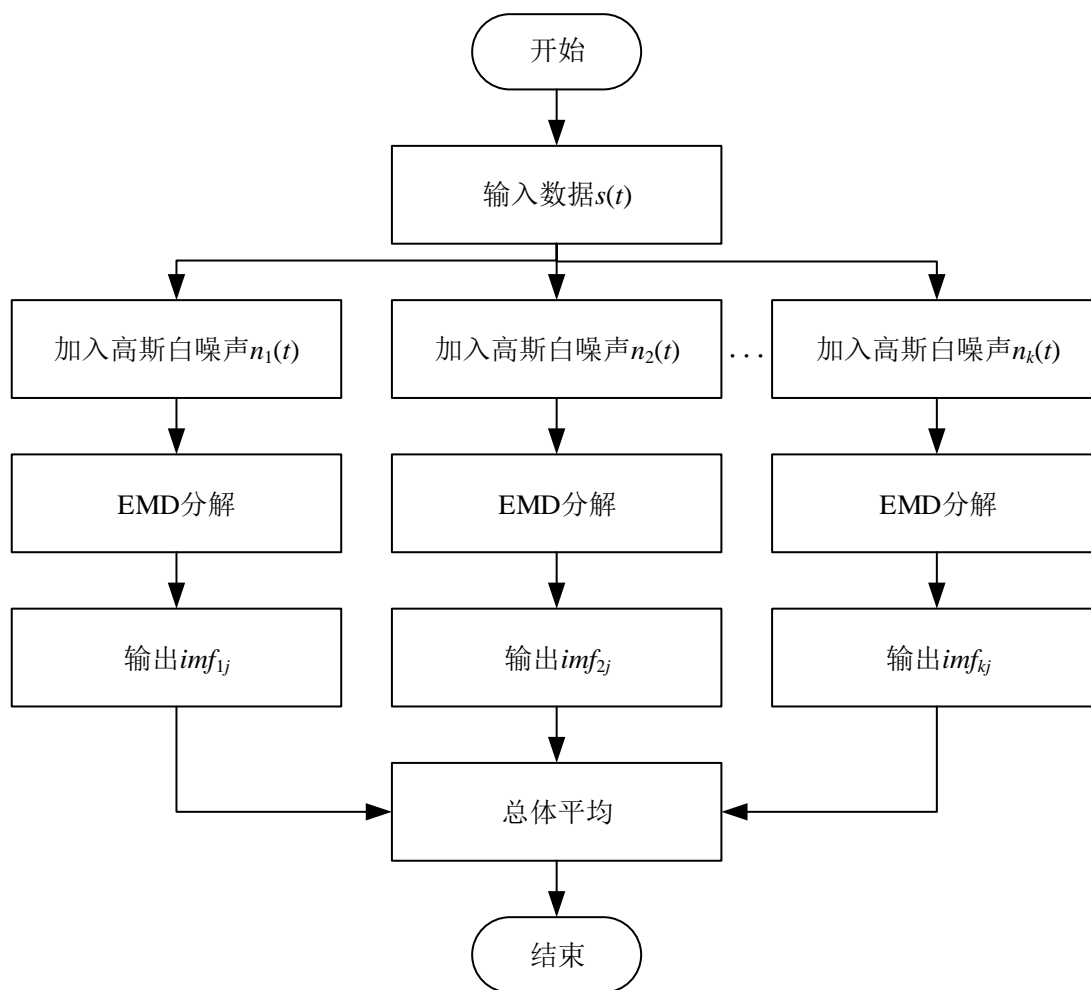


图 3.5 EEMD 分解流程图

在 EEMD 分解流程中可以看出, 加入的噪声次数越多, 最后总体平均时越容易抵消加入的高斯白噪声所带来的影响, 但是会明显增大计算难度; 反之若是加入噪声次数较少, 则可能给分解结果带来不利的影响。因此应当选择适当的噪声加入次数, 一般选择 50 次以上。

3.3 基于 EEMD-SE 的故障诊断方法

3.3.1 卷积神经网络

卷积神经网络 (CNN)，是一种模仿生物神经网络结构的数学模型，CNN 由大量的神经元按照一定的结构组合成为网络，能够做出类似人的简单判断，在图像处理，自然语言处理等领域有着广泛的应用，并取得了良好的效果^[57]。卷积神经网络一般可以分为卷积层、池化层和全连接层。

(1) 卷积层

卷积层是 CNN 网络组成的重要部分，有着提取目标特征的作用，也是整个 CNN 网络中计算量很大的一部分。CNN 网络通常包含多个卷积层，随着卷积层深度的增加，提取到的特征也更加抽象。卷积层由具有参数学习能力的卷积核来构成，通过卷积核在目标矩阵上移动并进行卷积，从而得到新的矩阵。卷积层不同于传统数学上的卷积运算，而是使用矩阵的点乘求和来计算的，具体计算方式如图 3.6 所示。

2	2	2	2	2
2	1	1	1	2
2	1	2	1	2
2	1	1	1	2
2	2	2	2	2

(a) 输入矩阵

1	1	1
0	0	0
-1	-1	-1

(b) 卷积核

1	2	1
0	0	0
-1	-2	-1

(c) 输出矩阵

图 3.6 卷积层示例图

由图 3.6 可以看出，输入卷积层的是一个 5×5 的矩阵，卷积核是一个 3×3 的矩阵。首先，将输入矩阵阴影部分与卷积核对应位置相乘后相加，得到第一个输出特征。在图

中表示为 $[[2,2,2],[2,1,1],[2,1,2]]$ 与卷积核 $[[1,1,1],[0,0,0],[-1,-1,-1]]$ 对应位置相乘后相加，得到第一个特征“1”。之后阴影部分在输入矩阵上移动一定的距离，得到新的特征，最终构成输出矩阵，这个移动距离称为步长，一般步长的设置应当小于卷积核大小，否则可能造成特征的缺失。图中所使用的步长为1，这样就得到的输出矩阵见图3.6(c)。为了更好的提取矩阵边缘的特征，有时会在输入矩阵的最外围填充一圈“0”或“1”，如图3.7所示。

0	0	0	0	0	0	0
0	2	2	2	2	2	0
0	2	1	1	1	2	0
0	2	1	2	1	2	0
0	2	1	1	1	2	0
0	2	2	2	2	2	0
0	0	0	0	0	0	0

图 3.7 填充后的输入矩阵

若输入矩阵的大小是 $W_1 \times H_1$ ，经过大小为 $F \times F$ 卷积核计算，得到的输出矩阵大小为

$$\begin{cases} W_2 = \frac{W_1 - F + 2P}{S} + 1 \\ H_2 = \frac{H_1 - F + 2P}{S} + 1 \end{cases} \quad (3.19)$$

其中， W_2 和 H_2 为输出矩阵的长和宽， F 为卷积核大小， P 为填充宽度， S 为卷积核的步长。

(2) 池化层

池化层也称为降采样层，池化层通常在卷积层之后，可以减少网络中参数的数量，提高模型训练速度^[58]。池化层的计算与卷积层相似，同样是对一个区域计算然后根据步长平移，重复对各个区域进行池化。池化通常有三种，分别为：最大池化、平均池化和随机池化。最大池化是在区域范围内选取最大值作为输出；平均池化是将区域内元素进行平均后最为输出；随机池化为随机选取区域内其中一个元素作为输出。池化层计算如

图 3.8 所示，图中步长为 1，池化窗口为 3×3 。

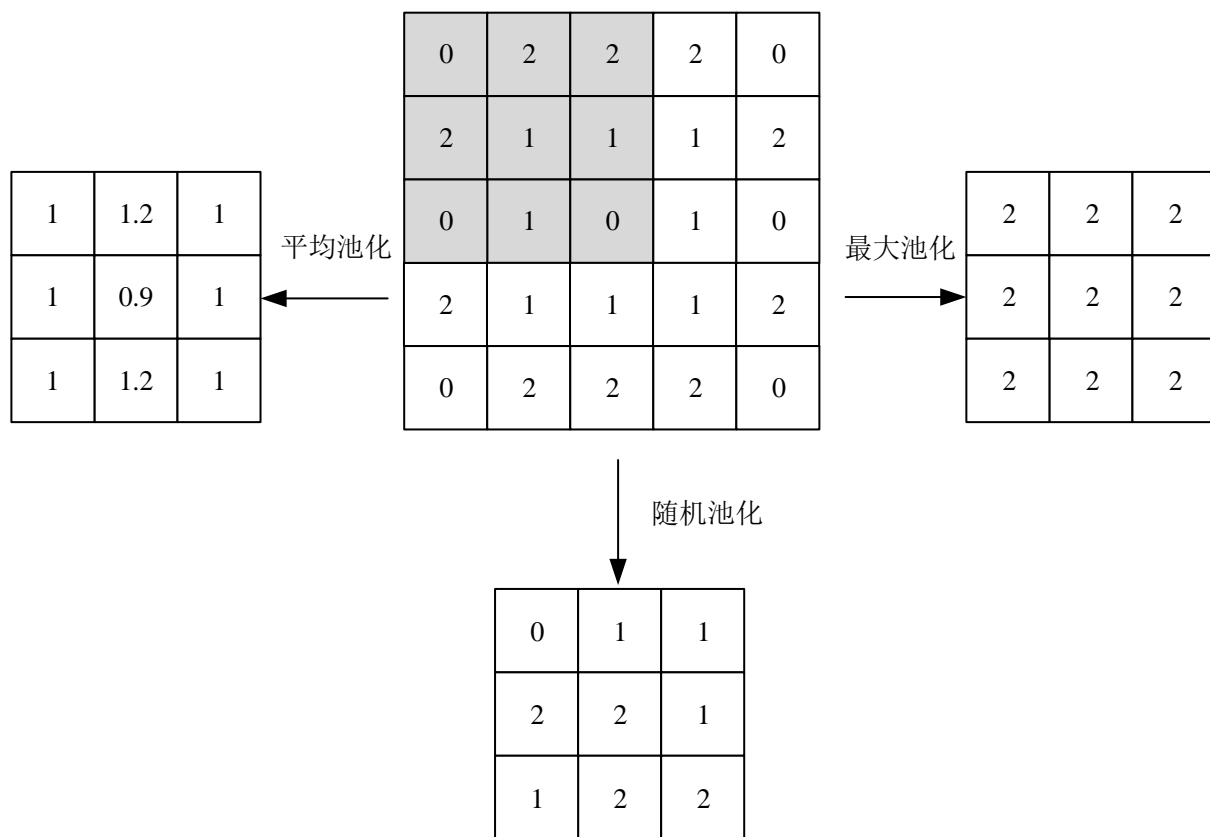


图 3.8 池化层示例图

(3) 全连接层

全连接层一般处于卷积神经网络的末尾，作用是将多维的矩阵转化为一维向量。如图 3.9 所示，全连接层每一个节点都与上一层连接，全连接层通常起到分类器的作用，用于整合特征和输出结果。相较于前面的卷积层，全连接层受特征空间位置所造成的差异影响较小，全连接层在一定程度上也可以看作特殊的卷积层，其卷积核大小为 1 的，步长也同样为 1。在全连接层后通常会直接输出分类结果，最后一层全连接层也称为输出层，其节点个数与输出结果个数相同。

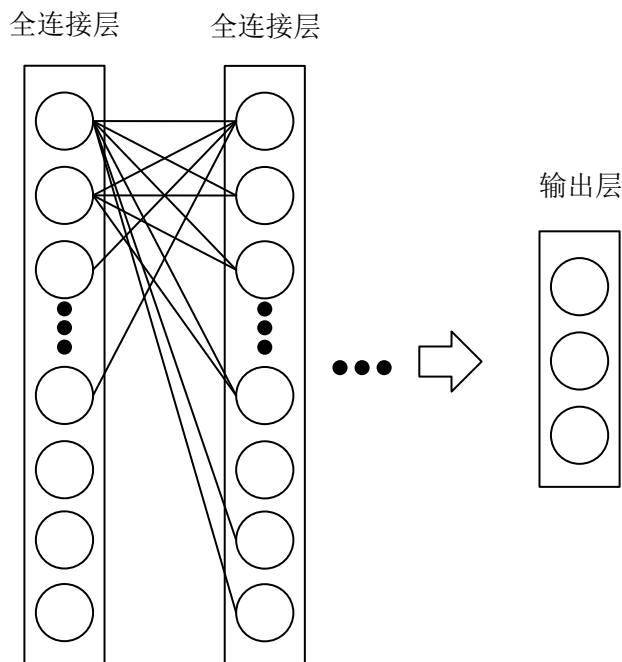


图 3.9 全连接层示例图

在卷积神经网络中卷积层虽然起到了特征提取的作用，但是产生了大量的参数与计算量，因此在其后接入池化层进行降采样，达到减少训练参数降低计算量的目的。对于风机的故障信号，在进行 EEMD 分解后，其特征已经得到了有效的提取，但是分解的不同 IMF 函数所蕴含的特征不同，因此在分类过程中应当重点关注包含更多特征的 IMF 函数，这样不但简化了模型，同时也提高了模型准确率，注意力机制则可以很好地处理这一问题。

3.3.2 通道注意力机制

注意力机制 (Attention Mechanism, AM) 借鉴了人类的视觉方式，人类的视觉在观察外界时并不会均等地关注整个视野，而是会选择性的关注大脑认为较重要的区域，甚至会忽视掉周围大脑认为不重要的区域^[59]，这样大脑会重点处理受重视的部分，而被忽视的部分则投入较少。神经网络在模拟人类大脑的过程中也可以对注意力机制进行应用，即对认为是重要的区域设置的权重更大，而对于不重要的区域则设置较小的权重。

注意力机制在图像中应用较为广泛，大致可以分为空间注意力机制、通道注意力机制和混合注意力机制。空间注意力机制通过捕获重要区域的特征从而达到空间注意力的效果；通道注意力机制则认为图片的不同通道所蕴含的信息重要性不同，选择出所含信息更多的通道从而达到通道注意力的效果；混合注意力机制则综合考虑了以上两点，对

空间和通道都有涉及。可以看出,对于风机的故障信号,在一个采样窗口中,其整个时域包含的特征信息分布没有出现明显的不均匀情况,在经过 EEMD 分解后,每一个 IMF 中的特征信息同样分布较为均衡,但是不同 IMF 中包含的特征信息相差较大。因此,通道注意力机制更适合这种情况。

通道注意力 (Channel-domain Attention, CA) 机制^[60],是一种软注意力机制方法。在卷积神经网络中,经过了一系列卷积层和池化层,会得到多个通道的特征矩阵,这些矩阵包含的信息量不同其重要程度也就不同,因此需要对各个通道赋予权值,突出较为重要的通道,同时降低特征信息含量较少通道的关注度。通过通道注意力机制,可以通过神经网络学习的方式,确定各个通道的权重。通道注意力机制的设计思想是:首先将各个通道的矩阵压缩为一个元素,这样整体就构成了一个一维向量;之后该一维向量就可以通过学习而表示各个通道的权重;最后将这个一维向量与原始的特征矩阵相乘,就得到添加注意力信息的特征矩阵。

通道注意力机制的代表结构是 SENet,相较于传统的 VGG, ResNet 等卷积神经网络结构,SENet 在这些结构的基础上,加入了 SE 模块这一通道注意力结构,对通道维度上的不同特征图进行了权重分配,加强了具有重要特征的特征图在分类任务中的作用。SE 结构可以分为两个部分,一个是 S 部分,用来计算权值;另一个是 E 部分,用来赋予权值,在几种的卷积神经网络中表明,SE 结构可以用较少的参数提高整体模型的准确度。SENet 的具体结构如图 3.10 所示。




图 3.10 SENet 结构图

输入的矩阵 R 通道数为 C' , 每个通道的矩阵长宽为 W' , 高为 H' , 即输入矩阵大小

为 $C' \times W' \times H'$ ，在经过一系列的卷积层和池化层后，得到了大小为 $C \times W \times H$ 的特征矩阵 Rn ；之后对每一个通道的矩阵进行全局平均池化得到 $1 \times 1 \times C$ 的一维向量 FC_1 ；将一维向量 FC_1 作为全连接输入，得到长度为 C/r 一维向量 FC_2 ，其中 r 根据输入的向量可以选择 2、4、8 以及 16 等值；之后全连接输入得到 $1 \times 1 \times C$ 的一维向量 FC_3 。全连接层所使用的激活函数为 ReLU 激活函数，其结构为

$$g(x) = \max(0, x) \quad (3.20)$$

其导数为

$$g'(x) = \begin{cases} 1, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (3.21)$$

ReLU 函数在 $x > 0$ 时梯度为 1，在 $x < 0$ 时梯度为 0，在 $x = 0$ 处不可导，但是默认此时梯度为 0。由于在 $(0, +\infty)$ 梯度为 1，因此不存在梯度消失问题，并且 ReLU 激活函数收敛较快，其函数图像如图 3.11 所示。




图 3.11 ReLU 激活函数

最后， FC_3 全连接输入并经过激活函数 sigmoid，使得权重向量归一化为 $(0,1)$ 区间，之后与原始输入矩阵点乘，就得到了包含通道注意力信息的特征矩阵 T 。sigmoid 激活函数数学表达式为

$$h(x) = \frac{1}{1 + e^{-x}} \quad (3.22)$$

其导数为

$$h'(x) = \frac{1}{1+e^{-x}} \left(1 - \frac{1}{1+e^{-x}}\right) \quad (3.23)$$

也可以表示为

$$h'(x) = h(x)(1-h(x)) \quad (3.24)$$

sigmoid 激活函数多用于分类判断网络，输出区间在 (0,1) 之间且单调递增，其函数图像如图 3.12 所示。




图 3.12 sigmoid 激活函数

3.3.3 故障诊断网络结构

公路通风设备故障实验台所采集的数据为 6 个维度，包含 3 轴的加速度数据和 3 轴的角加速度数据，在进行数据预处理后，对每一个维度分别进行 EEMD 分解，原始信号经过 EEMD 分解后会得到一系列的本征模态函数 (IMF)，但是不同的 IMF 所包含的信息不同，包含的信息重要程度也不同，在进一步提取 IMF 中的特征时，不仅需要关注每一个 IMF 中的特征，同时要关注 EEMD 分解出的某些 IMF 更能体现故障信息的特征。因此在 EEMD 分解后加入通道注意力机制 (EEMD-SE)，使得后续的神经网络学习在携带较为重要故障信息的 IMF 上赋予的权重更高，以达到提高整个故障诊断模型精度的目的。本文所提出的 EEMD-SE 算法流程如图 3.13 所示。

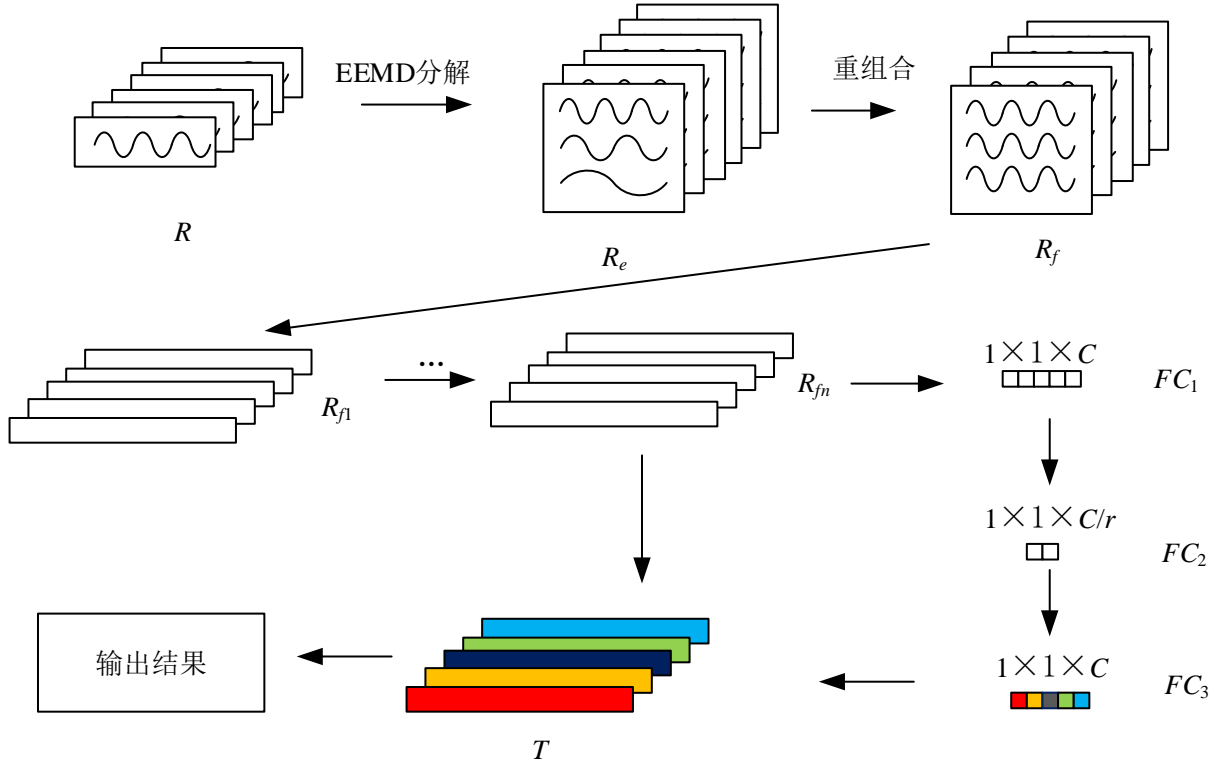


图 3.13 EEMD-SE 算法结构图

EEMD-SE 算法流程如下。

(1) 输入预处理后的六维信号 R ，在每个维度上分别进行 EEMD 分解，得到 IMF 函数并选取前五个 IMF 组成 6 通道特征矩阵 R_e 。

(2) 由于不同 IMF 函数所包含的特征不同，而 6 个不同维度所形成的通道所包含特征可以认为相差不大，因此通道注意力机制所赋予的权值应当针对不同的 IMF 而不是不同的维度，所以需要特征矩阵 R_e 进行重组，将不同维度同一个 IMF 序列整合为一个通道，得到重组后矩阵 R_f

$$\begin{bmatrix} [imf_{11}(t), imf_{21}(t), imf_{31}(t), \dots, imf_{i1}(t)] \\ [imf_{12}(t), imf_{22}(t), imf_{32}(t), \dots, imf_{i2}(t)] \\ \dots \\ [imf_{1j}(t), imf_{2j}(t), imf_{3j}(t), \dots, imf_{ij}(t)] \end{bmatrix} \Rightarrow \begin{bmatrix} [imf_{11}(t), imf_{12}(t), imf_{13}(t), \dots, imf_{1j}(t)] \\ [imf_{21}(t), imf_{22}(t), imf_{23}(t), \dots, imf_{2j}(t)] \\ \dots \\ [imf_{i1}(t), imf_{i2}(t), imf_{i3}(t), \dots, imf_{ij}(t)] \end{bmatrix} \quad (3.25)$$

其中， $imf_{ij}(t)$ 表示第 j 个维度的信号分解得到的第 i 个 IMF 函数。

(3) 将重组后的特征矩阵输入全连接层，具体结构如图 3.14 所示。

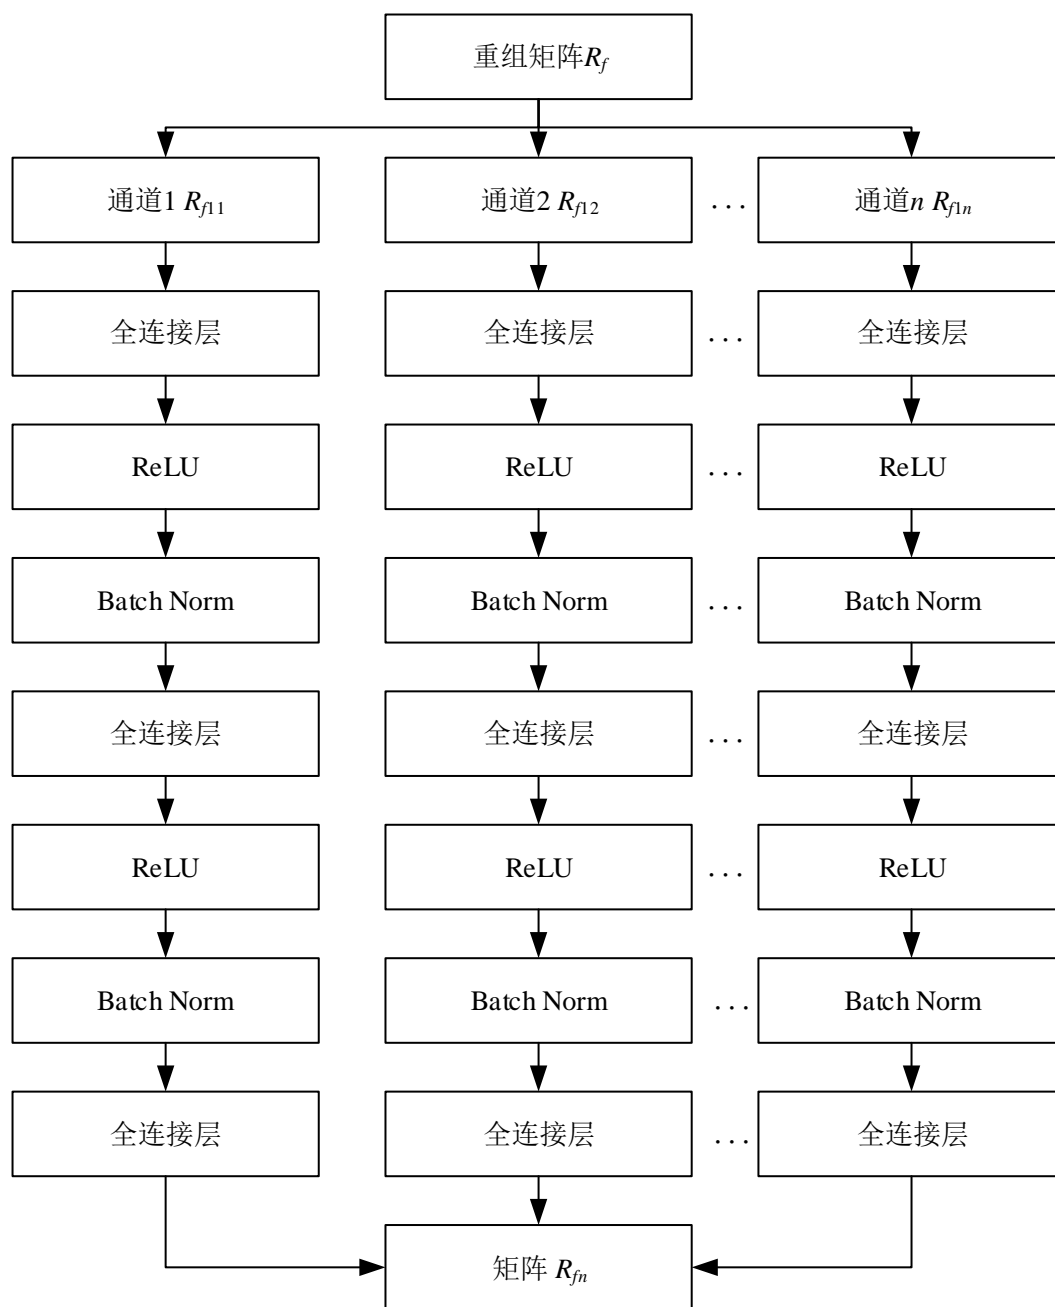


图 3.14 全连接层结构图

全连接层的具体流程为：

- 1) 将重组后的输入矩阵分为不同通道，并将不同通道分别作为全连接输入；
- 2) 经过 relu 激活函数后进入 Batch Norm 层，Batch Norm 层也称为正则化层，在下一个全连接层前加入 Batch Norm 层对矩阵进行规范化，可以使梯度下降在训练时更好收敛。Batch Norm 层首先对输入归一化到零均值和单位方差，之后通过神经网络训练的方式自适应的对方差和均值进行缩放和平移，达到最佳的规范化；
- 3) 将规范化的矩阵输入下一个全连接层，再次使用 ReLU 激活并输入 Batch Norm

层;

4) 经过全连接层后输出, 作为未添加注意力机制的特征矩阵 R_{fn} 。

(4) 对矩阵 R_{fn} 提取通道注意力权重, 其步骤如下:

1) 将每个通道分别进行平均池化得到一维向量 FC_1 , 由于选取 EEMD 分解的前五个 IMF, 因此 FC_1 大小为 $1 \times 1 \times 5$;

2) 经过 ReLU 函数激活后, 输入到输出为 2 的全连接层 FC_2 ;

3) 之后再次经过 ReLU 函数激活, 输入到输出为 5 的全连接层 FC_3 , FC_3 为矩阵 R_{fn} 的通道注意力权重向量。

(5) 权重向量 FC_3 经过 sigmoid 函数激活后, 与矩阵 R_{fn} 点乘, 得到带有通道注意力信息的特征矩阵 T 。

(6) 将特征矩阵 T 输入输出层, 得到故障诊断结果。

3.4 本章小结

本章主要介绍了提出的 EEMD-SE 公路通风设备故障诊断模型的理论及结构流程。在本章中首先论述了数据预处理的方法, 之后论述了信号特征提取的方法和基于注意力机制的故障判别方法, 最后搭建了 EEMD-SE 故障诊断模型, 并介绍了算法模型结构与算法理论。

第四章 公路隧道通风设备故障诊断实验

本章首先通过公路隧道通风设备故障实验台所采集的数据，验证第三章提出的EEMD-SE 故障诊断模型，并对实验结果进行分析，然后与其他几种算法进行对比从而验证模型的准确度，最后设计一种包含实时故障诊断功能的公路隧道风机监控系统。

4.1 通风设备故障数据与预处理

4.1.1 通风设备故障数据

通过故障实验台共采集了 5 个状态下风机运行的振动数据，分别为正常状态、叶轮松动状态、转子断条状态、电压不足状态和固定件松动状态。实验台采样率在 720Hz 以上，每种故障采集时间在 15 分钟左右，所有状态共采集 3464862 条数据，每条数据包括 6 个维度，并且在采集风机不同运行状态的数据时，传感器与风机主体的相对位置不会发生改变，故障实验台采集的部分数据见表 4.1-4.5，其中的数据为传感器采集的原始无量纲数据，其数据的取值范围是-32768 - +32767。

表 4.1 风机正常运行状态部分数据

序号	accx	accy	accz	gyrox	gyroy	gyroz
1	354	6156	15480	-21	-58	-2
2	176	6052	16140	-25	-53	-9
3	-242	5422	17354	-28	-45	-9
4	-508	5504	17494	-24	-27	2
5	-376	6386	16662	-18	-21	6
6	466	6806	14356	-8	21	-10

表 4.2 风机叶轮松动状态部分数据

序号	accx	accy	accz	gyrox	gyroy	gyroz
1	1090	6500	20324	-50	-82	55
2	2534	9202	20192	4	0	20
3	4750	9620	17406	43	56	-25
4	2824	9272	8634	32	47	-103
5	-2370	4514	6468	-40	8	-104
6	-4602	1322	12890	-94	-44	-83

表 4.3 风机转子断条状态部分数据

序号	accx	accy	accz	gyrox	gyroy	gyroz
1	-1180	4520	13130	-45	-52	-20
2	-1048	2752	17322	-37	-58	5
3	788	3698	18966	-1	-12	32
4	3474	8790	17400	13	19	18
5	3778	9568	13322	17	39	-9
6	2948	8682	10172	-30	16	-62

表 4.4 风机电压不足状态部分数据

序号	accx	accy	accz	gyrox	gyroy	gyroz
1	1946	4880	12240	-23	-21	-14
2	1906	5136	12702	-29	-39	-10
3	1576	5502	13954	-30	-44	-8
4	1428	5366	14268	-34	-46	-11
5	852	4984	14776	-34	-47	-9
6	362	5120	15112	-31	-49	-7

表 4.5 风机固定件松动状态部分数据

序号	accx	accy	accz	gyrox	gyroy	gyroz
1	3054	6856	13528	-14	17	-43
2	2914	6406	13008	-29	7	-45
3	2866	6038	13272	-32	-8	-38
4	3116	6264	13926	-26	-35	-22
5	3732	6858	15028	-21	-36	-23
6	3678	6850	15002	-18	-29	-31

表 4.1-4.5 中展示了 5 种状态下部分故障实验台所采集的数据，其中 accx、accy 和 accz 表示的是 3 轴的加速度数据，gyrox、gyroy 和 gyroz 则表示 3 轴的角加速度数据。可以看出：

(1) 加速度计与陀螺仪的数据数值相差较大，需要进行归一化等操作，否则可能会导致后续故障诊断模型中忽略数值较小的角加速度变化，从而影响模型的判断精度；

(2) 各种状态的信号不只是拥有不同的频率，同时还拥有不同的幅值信息，因此在进行归一化时需要将不同状态的信号拼接后再进行归一化，若是对单一的状态分别进行归一化则会失去一定的幅值信息；

(3) 若出现异常值，则会影响归一化时的效果，因此在归一化之前需要去除异常

值。

4.1.2 故障数据异常值处理

通过风机故障实验台采集的原始数据通常存在重复、缺失和数值异常等问题，具体见表 4.6。

表 4.6 部分异常数据

序号	accx	accy	accz	gyrox	gyroy	gyroz
1	-35	28				
2	2914	6406	13008	-29	7	-45
3	-86	-10230	11760	312128	40	-6
4	-86	-10230	11760	312128	40	-6
5	-86	-10230	11760	312128	40	-6
6	1176	5584	14384			
7	-336	5468	16710	-21	-49	-2
8	-286	6020	16618	-13	-40	6
9	-120	6584	16640	23234	-37	3
10	-2	6614	17014	-11	-28	-9
11	-336	5468	16710	-21	-49	-2

从表 4.6 中可以看出，异常数据包括数据缺失、数据重复和数值异常 3 种情况。

(1) 如第 1、6 行数据所示，6 个维度的数据出现了缺失，只保留了部分维度数据。这类数据较多出现在数据采集的开始和结尾，小部分出现在其他位置。出现在开头和结尾的原因是开始保存数据时数据传输处于一条数据的中间位置，这样会出现保存到传输了一半的数据。在结尾出现的原因类似，在结束数据保存时一条数据正在传输过程中，因此会记录到不完整的数据。出现在其他位置的原因为，由于外界干扰而在传输时会有小概率出现数据丢失，从而出现维度缺失的数据。对于此类的数据在预处理时会进行删除操作。

(2) 如第 3、4、5 行数据所示，连续出现了完全相同的数据，这在频率较高的风机振动信号中几乎不可能出现，并且这类故障出现的次数很少。这类数据的出现可能是由于传感器故障或 IIC 传输干扰造成的，不能正确反应当前的风机状态，反而会干扰后续故障诊断模型对当前的风机状态的判断，影响模型精度，因此对于此类的数据在预处理时会进行删除操作。

(3) 如第 9 行数据所示，某一维度的数值远大于其他数据，这种数据的出现一般是由于传输出错导致，对此类的数据在预处理时会进行删除操作。在采集的数据中还存

在一些数值大小差异很大的数据，此类数据是由于外界振动干扰造成的。因此这类数据不能体现风机当前时刻的运行状态信息，同样可以直接删除。对以上两种原因造成的数值异常数据，采用箱线图的方式进行删除。由于不同状态的数值有所差别，不同维度的数值同样有所差别，若对所有数据直接进行箱线图删除则会删除许多有用的数据，所以应当对每个状态的每个维度单独进行箱线图操作，其中一个状态的一个维度如图 4.1 所示。




图 4.1 箱线图处理结果图

4.1.3 故障数据归一化

归一化的数据要消除加速度数值与角加速度数值之间差距过大所造成的影响，同时需要保留不同状态的幅值差异信息。具体做法为，首先将所有数据基准数据归零，这一步将各种状态的数据与静止时的数据作差，从而起到传感器置零的作用；之后将加速度维度与角加速度维度分割，并将风机不同状态的加速度与角加速度数据拼接；然后对拼接后的加速度数据和角加速度数据分别进行归一化；最后将归一化后不同状态的数据分割，再分别将不同状态的加速度数据与角加速度数据拼接，就得到了归一化后的结果，归一化后部分数据如表 4.7 所示。

表 4.7 归一化后部分数据

序号	accx	accy	accz	gyrox	gyroy	gyroz
1	0.24105461	0.23081451	0.04284369	0.2994923	0.1979693	0.0761421
2	0.25423728	0.3701742	-0.1370056	0.1167512	0.2994923	-0.2284263
3	0.02071563	0.16372410	-0.3895954	-0.0050761	0.3807106	-0.50253807
4	-0.3239171	-0.1032250	-0.6198210	-0.1370558	0.1776649	-0.6040609
5	-0.2052730	-0.3000235	-0.6214689	-0.5025380	-0.4923857	-0.05583756
6	-0.2638888	-0.1220574	0.65136534	-0.4010152	-0.6142131	0.27918781
7	0.02306968	0.08392184	0.53036723	0.36040609	-0.3096446	0.46192893
8	0.38983050	0.53095574	0.25847457	0.48223350	0.13705583	0.26903553
9	0.50376647	0.61428907	0.14595103	0.60406091	-0.0659898	0.57360406
10	0.51247646	0.55402542	-0.4613935	0.38071066	0.19796954	0.03553299
11	0.30696798	0.42055084	-0.2297551	-0.6243654	0.02538071	-0.5837563

数据归一化后，需要将整个数据通过一个个观察窗口进行切片，并为每一个切片做相应标签。由于采样率大约为 720Hz，即每秒有 720 个采样点，同时风机的旋转频率为 24Hz，在保证每个切片拥有完整的周期信息时，也要使后续神经网络训练拥有较多的切片数量。因此可以设置每个切片拥有 200 个采样点，总数据量为 3444205 条，共得到切片 17219 个。各状态归一化后数据如图 4.2 所示，其中横坐标表示采样点，纵坐标为归一化后的数值，均无量纲。通过图 4.2 分析可得：

(1) 各信号的幅值有所差异，其中叶轮松动的幅值最大，远大于正常状态信号的幅值；转子断条的幅值次之，略大于正常状态信号的幅值；正常状态、固定件松动状态和电压不足状态幅值相差不大，电压不足状态并没有因为供电不足而产生明显幅值减小的结果；

(2) 正常状态和电压不足状态信号中 accz 和 gyroy 维度，固定件松动状态的 gyroz 维度可以观察到明显的周期变化，并且与风机的旋转频率基本一致，可以认为产生周期信号的原因是风机自身运行产生了振动。这三种状态的其他维度周期特征不明显，是否存在周期特征需要进一步的特征提取；

(3) 转子断条状态与叶轮松动状态未出现明显的周期信号，各维度信号杂乱且频率较高，出现这种情况的原因是故障所产生的振动影响了风机本身正常运行的振动，从而影响了正常运行时周期性的信号表达，但在进一步的特征提取中可能重新获得与风机旋转频率相同的周期信号。





图 4.2 各状态波形图

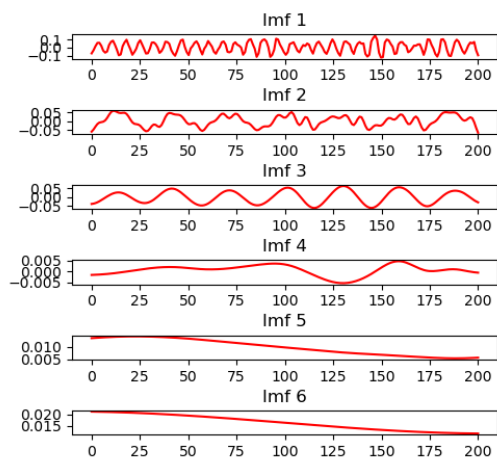
4.2 基于 EEMD-SE 结构的通风设备故障诊断方法

4.2.1 EEMD 集合经验模态分解


对经过预处理的数据进行分片后,需要进行特征提取步骤,即 EEMD 分解。对每个切片的每个维度分别进行 EEMD 分解,其中加入的白噪声频率为 20000Hz,加入白噪声次数为 50 次,得到的结果如图 4.3-4.7 所示,其中横坐标表示采样点,纵坐标为归一化后的数值,均无量纲。正常状态的 EEMD 分解结果如图 4.3 所示。




(a) 正常状态 accx 分解结果




(b) 正常状态 accy 分解结果




(c) 正常状态 accz 分解结果



(d) 正常状态 gyrox 分解结果



(e) 正常状态 gyroy 分解结果




(f) 正常状态 gyroz 分解结果


图 4.3 正常状态 EEMD 分解结果图

由图 4.3 风机在正常运行状态下振动信号的 EEMD 分解结果可以看出。首先，6 个维度在第 3 个 IMF 中都出现了规律的周期信号；其次，各维度中第 1 个 IMF 出现不规则的高频信号；之后，在 accy、gyrox 和 gyroz 三个维度在第 2 个 IMF 中出现了较为明显的近似正弦的周期信号，并且各个维度的信号较为相似；最后，可以看出序号越靠后的 IMF 频率越低，序号最大的 IMF 蕴含的特征信息也较少。


叶轮松动状态的 EEMD 分解结果如图 4.4 所示，根据图 4.4 风机处于叶轮松动状态下的分解结果可以看出，首先，相较于正常状态其信号幅值明显较大；其次，该状态下的高频 IMF 基本处于无规则振动状态，并且除 gyroy 维度外，其他维度的 IMF 均未出现明显的周期信号，这可能是由于叶轮松动造成的剧烈振动干扰了风机的正常运转；最后，该状态下各个维度的运动出现明显的差异。




(a) 叶轮松动状态 accx 分解结果




(b) 叶轮松动状态 accy 分解结果




(c) 叶轮松动状态 accz 分解结果



(d) 叶轮松动状态 gyroX 分解结果




(e) 叶轮松动状态 gyroY 分解结果




(f) 叶轮松动状态 gyroZ 分解结果

图 4.4 叶轮松动状态 EEMD 分解结果图


转子断条状态的 EEMD 分解结果如图 4.5 所示。




(a) 转子断条状态 accx 分解结果




(b) 转子断条状态 accy 分解结果




(c) 转子断条状态 accz 分解结果



(d) 转子断条状态 gyrox 分解结果



(e) 转子断条状态 gyroy 分解结果




(f) 转子断条状态 gyroz 分解结果


图 4.5 转子断条状态 EEMD 分解结果图

根据图 4.5 分析可得，首先，与正常状态相比，转子断条状态下的整体振幅大于正常状态；其次，该状态的第 3 个 IMF 分量中出现了不明显的正弦周期信号，相较于正常状态有着较大的形变，其中 accx 和 gyroy 维度最为明显，这表明转子断条状态下风机的振动仍然具有较为规律的周期性；最后，该状态高频 IMF 规律性同样不强，但可能蕴含着需要进一步提取的特征信号。


电压不足状态的 EEMD 分解结果如图 4.6 所示。根据图 4.6 分析可得，首先，电压不足状态与正常状态相似，各维度都在第 3 个 IMF 中出现明显的周期信号，但波形略有差别；其次，该状态下在 accz、gyrox 和 gyroy 维度，其中的第 2 个 IMF 出现了较为规律的周期信号；最后，该状态各维度的第 1 个 IMF 都为不规则的高频信号。




(a) 电压不足状态 accx 分解结果




(b) 电压不足状态 accy 分解结果




(c) 电压不足状态 accz 分解结果



(d) 电压不足状态 gyrox 分解结果




(e) 电压不足状态 gyroy 分解结果




(f) 电压不足状态 gyroz 分解结果

图 4.6 电压不足状态 EEMD 分解结果图


固定件松动状态的 EEMD 分解结果如图 4.7 所示。




(a) 固定件松动状态 accx 分解结果




(b) 固定件松动状态 accy 分解结果




(c) 固定件松动状态 accz 分解结果



(d) 固定件松动状态 gyrox 分解结果



(e) 固定件松动状态 gyroy 分解结果



(f) 固定件松动状态 gyroz 分解结果

图 4.7 固定件松动状态 EEMD 分解结果图

根据图 4.7 分析可得，首先，固定件松动状态下，与正常状态相似，各维度都在第 3 个 IMF 中出现明显的周期信号；其次，固定件松动状态各维度的第 1 个 IMF 出现了

明显的周期信号，这与固定件松动引起了风机的整体晃动有关，使其以大于风机自身旋转频率的频率振动；最后，该状态 *accy*、*accz* 和 *gyroy* 维度的第 2 个 IMF 出现了较为规律的周期信号。

通过风机故障实验台的正常状态、叶轮松动状态、转子断条状态、电压不足状态和固定件松动状态进行 EEMD 分解，并对其分解结果的对比可以看出。

(1) 周期信号一般会出现在各个维度的第 3 个 IMF 中，这个周期信号的频率与风机自身转动的频率基本一致，表明风机自身转动是这个信号产生的主要原因，其中正常状态和固定件松动状态的周期信号较为清晰；电压不足状态在第 3 个 IMF 中的周期信号略有变形，是由于电压不足所导致风机运转不正常；转子断条状态的第 3 个 IMF 中信号的周期变形较大，是由于转子损坏导致的风机中电机的转动不平衡，并且转子断条带来的振动会对风机本身运行时产生的振动信号造成干扰；叶轮松动状态信号分解的 IMF 则没有明显的周期特征，是由于叶轮与转轴碰撞所产生的振动远大于风机自身运行所产生的振动，干扰了风机整体的正常振动。

(2) 各信号 EEMD 分解得到的 IMF 幅值有所不同，尤其是在前几个 IMF 中，其中叶轮松动状态的幅值最大，转子断条状态次之，其余的状态即正常状态、固定件松动状态和电压不足状态的幅值相差不大。电压不足状态并没有因为电压不足导致振动减小，而是与正常状态相似。这些不同状态 IMF 表现的幅值特征与各状态原始信号相似，EEMD 分解后同样可以体现信号的幅值特性。

(3) 在固定件松动状态中，EEMD 分解的高频本征模态函数（第 1 个 IMF）呈现出周期特性，这与固定件松动导致的风机震荡有关。而其他状态的高频本征模态函数往往是无规则信号，这类信号含有较多本状态的信号特征，但是较难提取，因此需要进一步对 IMF 进行特征提取并加以分类。

(4) 同一状态中不同的 IMF 所包含的特征信息不同，如第 3 个 IMF 中包含的周期信号可以很大程度体现该状态特征；高频的 IMF 往往也包含重要的特征信息，如固定件松动状态的第 1 个 IMF 表现出明显的周期信息；序号较大的 IMF 往往较为简单，所蕴含的状态信息也较少。因此在对 IMF 进行进一步特征提取并分类的过程中，加入对不同 IMF 的注意力机制会有一定的效果。

4.2.2 实验结果分析

分片后的数据经过 EEMD 分解后，每一维度取前五个 IMF，并且将不同维度同一个序号的 IMF 进行拼接作为一个通道，得到 $5 \times 6 \times 200$ 的矩阵。送入后续带有注意力机制的神经网络中训练，完成 EEMD-SE 模型的实现。数据集中包含上述的正常、叶轮松动、转子断条、电压不足以及固定件松动 5 种状态。EEMD-SE 算法在风机故障实验台采集数据集上的精确率和召回率，以及其他算法在该数据集上的结果见表 4.8 和表 4.9。

表 4.8 EEMD-SE 与不同结构模型对比

算法模型	准确率	召回率
EEMD-SE	99.977%	99.981%
EEMD-MLP	99.907%	99.908%
MLP	99.814%	99.831%

由表 4.8 可以看出，本文提出的 EEMD-SE 模型在该数据集上有着较好的效果，可以有效的完成对风机故障的诊断。本文提出的 EEMD-SE 模型与不加入注意力机制的 EEMD-MLP 模型对比可以看出，加入注意力机制后模型的准确率与召回率都有着一定的提高；EEMD-MLP 模型与不加入 EEMD 部分的 MLP 模型进行比较可得，EEMD-MLP 模型准确率与召回率更高，说明 EEMD 部分进行特征提取在故障诊断过程中发挥着一定的作用。

表 4.9 EEMD-SE 与其他经典模型对比

算法模型	准确率	召回率
EEMD-SE	99.977%	99.981%
SVM	77.625%	76.082%
EEMD-SVM	97.653%	97.465%
CNN	96.863%	97.808%

由表 4.9 可以看出，本文提出的 EEMD-SE 模型与经典的 SVM，CNN 算法相比，具有更好的故障诊断效果；并且加入了 EEMD 的支持向量机模型相较于直接使用 SVM，准确率和召回率有着明显的提升，说明了特征提取在故障诊断中发挥着重要的作用；整体来看使用神经网络在风机故障诊断中相较于传统的 SVM 模型都具有较好的效果。

EEMD-SE 模型在 5 种状态下的混淆矩阵如图 4.8 所示。在图 4.8 中，纵轴代表数据的真实值，横轴代表模型的预测值，热力图的深浅代表这一情况所占比例的大小，数字表示这一情况出现的具体比例。可以看出故障诊断模型对 5 种状态的判断效果整体较好，对于正常状态、叶轮松动状态、电压不足状态和固定件松动状态可以完全准确的判断，

但是对于转子断条状态会有 0.096%的情况判断为叶轮松动状态。转子断条与叶轮松动状态在经过 EEMD 分解后都存在周期信号不明显的情况，转子断条相较于叶轮松动的周期信号较为明显，若存在外界的干扰则会使转子断条状态的振动信号短时间内周期性消失，从而与叶轮松动状态的振动信号相似。

若是对状态进行二分类，分为正常状态和异常状态，其中异常状态包括上述的 4 种故障状态，则模型的判断精度可以达到 100%，这说明该模型对异常状态的判断精确度有着较高的水平。




图 4.8 EEMD-SE 模型混淆矩阵热力图

4.3 公路隧道通风设备监控系统

4.3.1 通风设备监控系统功能设计

随着公路隧道里程数以及隧道长度的增加，公路隧道通风设备的重要性也逐渐体现，其信息化的重要性也日益凸显。为了保证作为主要通风设备的风机正常运转，不只是需要完成风机的监测功能，出现问题时，还需要及时地进行故障诊断。目前隧道风机大多使用人工巡检的手段来维护，及时性不强。若能及时发现风机的故障，可以对风机及时进行针对性维修，从而避免造成更大的损失。因此，需要提出一种结合隧道风机故障诊

断功能的监控系统。隧道风机监控系统功能如图 4.9 所示。

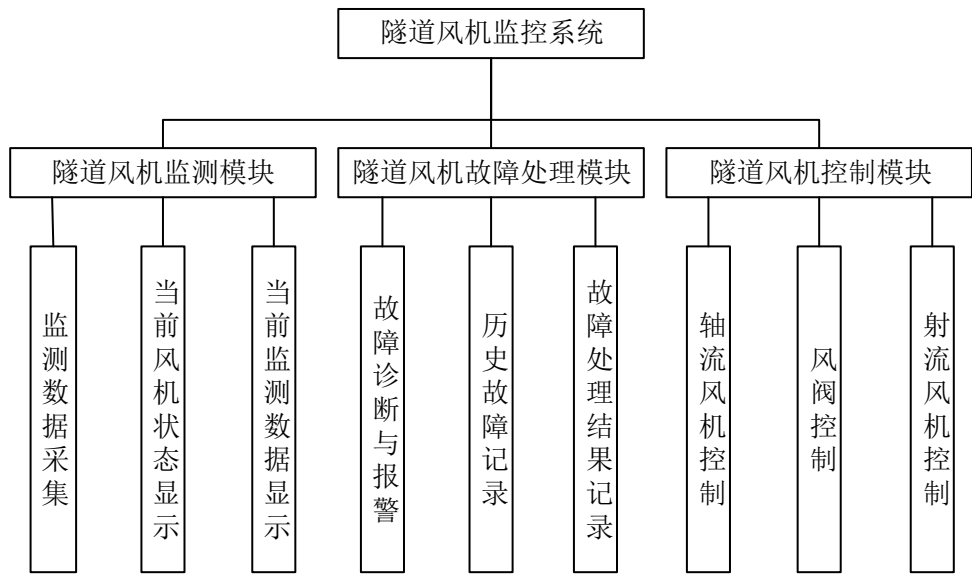


图 4.9 隧道风机监控系统功能图

隧道风机监控系统由三部分构成，分别是隧道风机监测模块、隧道风机故障处理模块和隧道风机控制模块。

隧道风机监测模块用以监测和显示风机的数据，包括以下功能：

- （1）监测数据的采集，包括温度、湿度和振动信号，采集的数据向服务器传输，用以故障诊断和数据显示；
- （2）当前风机状态显示，包括显示风机是启动或停止状态，以及显示风机处于正常运行或是某种故障状态；
- （3）当前监测数据显示，包括显示采集的温度、湿度数据以及风机转速位置等基本信息，由于振动信号不能直观反应风机的状态，因此不显示振动信号。

隧道风机故障处理模块用以进行故障诊断与故障记录，包括以下功能：

- （1）故障诊断与报警，通过所提出的 EEMD-SE 故障诊断算法与温度报警结合，对故障进行诊断，在诊断过程中为了尽量防止误报，将报警条件设置为连续 5s 采集的数据振动数据判定为故障时触发报警并发送故障诊断信息，温度报警则设置为连续 10s 达到高温报警阈值，触发报警。触发报警后将报警信息发送到隧道风机监测模块中当前风机状态显示部分；
- （2）历史故障记录，用于记录每次触发报警的时间、风机编号以及故障类型等信

息，以便后续检查或为科研提供数据支撑；

(3) 故障处理结果记录，用以记录故障持续时间，故障的类型，维修或更换的具体信息等。

隧道中通风设备大多为轴流风机和射流风机，因此隧道风机控制模块主要包括对隧道射流风机的控制和对轴流风机的控制以及对风道中风阀的控制，并且控制信息会同步到隧道风机监测子系统中当前风机状态显示部分，隧道风机监控系统结构如图 4.10 所示。

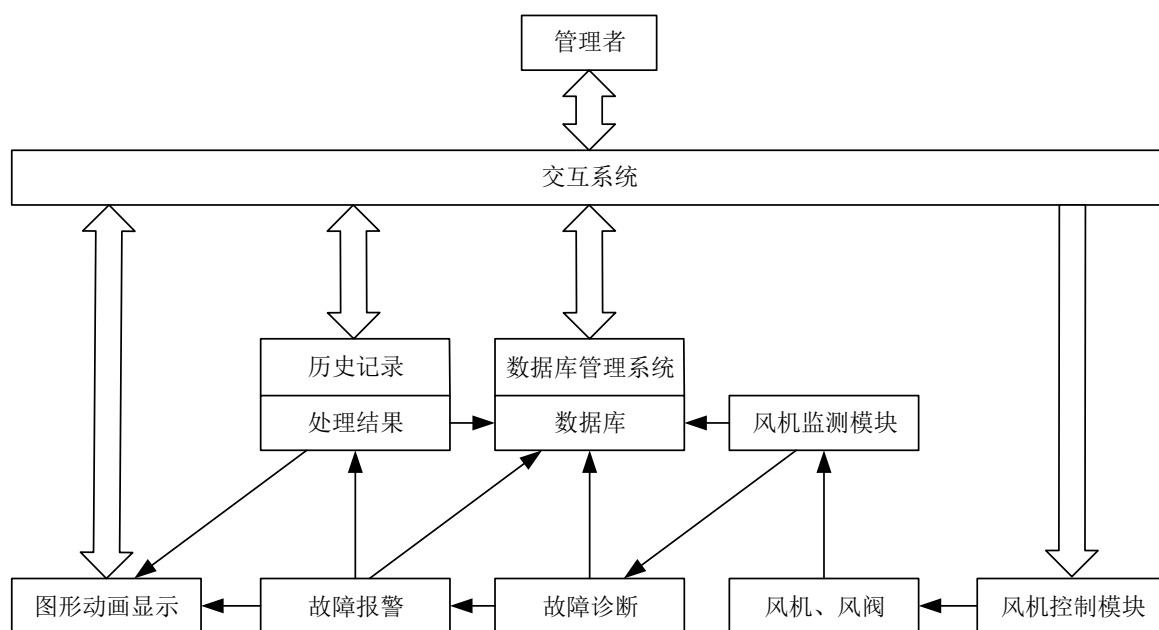


图 4.10 隧道风机监控系统结构图

管理者可以通过交互系统对系统内各种信息进行读取或对各种功能进行操作。交互系统可以对风机控制模块操作完成风机与风阀的控制；风机监测模块读取风机运行的各种数据上传至数据库并传输到故障诊断模块进行故障诊断；故障诊断模块通过监测信息完成故障诊断后若发现异常，则向数据库上传故障信息并触发故障报警，同时进行故障历史记录；故障报警与故障处理结果通过图形动画等可视化手段在交互系统中进行展示；交互系统可以读取风机运行数据以及故障信息并对这些信息进行操作。

4.3.2 隧道风机故障诊断模块结构设计

在进行隧道风机故障诊断模块的应用时，要考虑到目前隧道风机已经安装完成，并且风机由厂家提供，若数据采集系统需要修改风机结构，则较难实现，因此故障诊断模

块的布设应当避免对风机本身的修改，隧道风机故障诊断模块结构如图 4.11 所示。

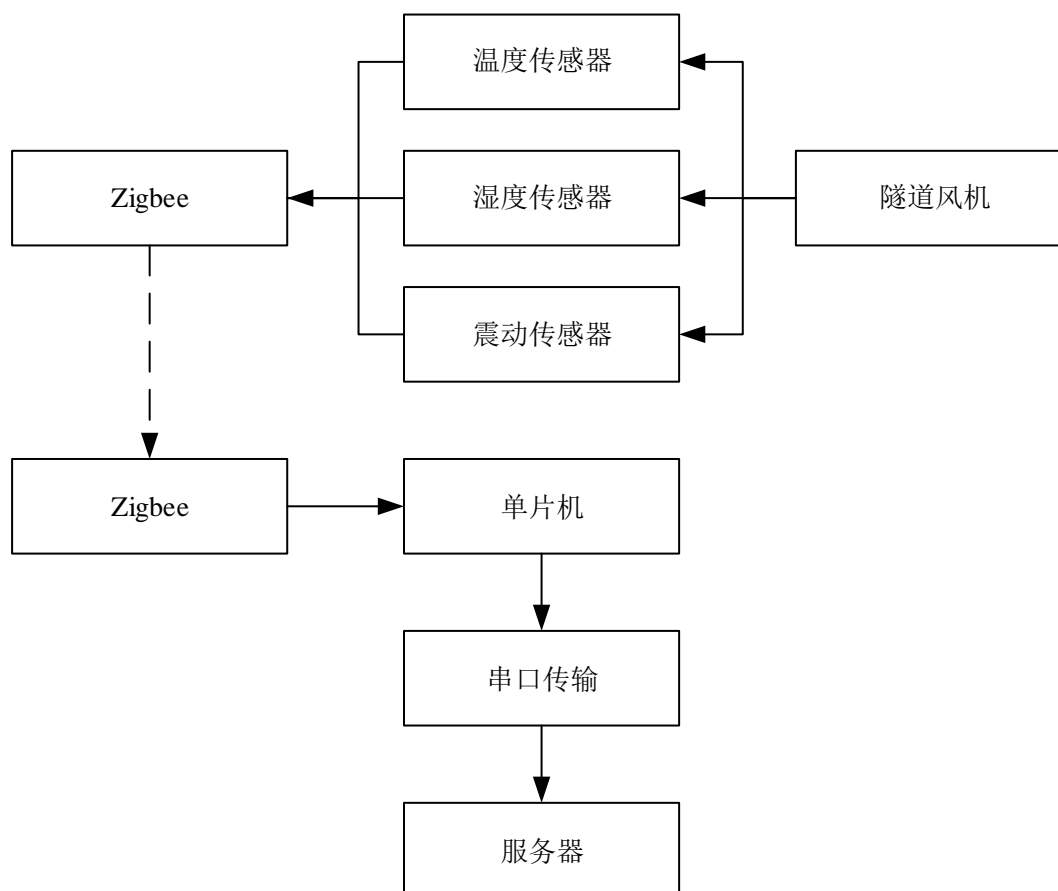


图 4.11 隧道风机故障诊断模块结构

温度传感器，湿度传感器和振动传感器可以安装在风机的电机与套筒之间，这些传感器信号的传输使用 Zigbee 无线模块，可以减少布设信号线对风机运行的干扰。可以看出，隧道风机故障诊断模块中传感器的安装均不会破坏风机本身的结构，在并且该模块结构简单，成本较低，易于实现。

当风机运行时，系统可以采集风机的温度、湿度和振动数据，这些数据无线传输给单片机并将范围内的多个传感器信号进行数据格式的转换与整合，然后经过有线的串口传输的方式传输给分布式服务器。服务器中可以根据故障诊断算法模型对振动信号处理，进行风机的故障诊断，为了避免某些瞬时信号产生干扰而导致误判，设定若在一定时间内连续判断为发生某种故障，则进行报警。同时，分布式服务器还会判断温度是否达到阈值并持续一段时间，若发生这种情况则认为风机过热，同样触发报警。分布式服务器向主服务器传输报警信息和采集到的温度湿度信息，用以显示风机的实时状态。

4.4 本章小结

本章首先分析了风机故障实验台所采集的数据特点并完成了原始数据的数据预处理；然后对预处理后的数据进行了 EEMD 分解并分析了不同状态下数据的特征；其次对比了本文提出的 EEMD-SE 故障诊断模型与其他经典模型的准确率与召回率，结果表明相较于其他模型，所提出的模型在风机故障数据上有着更好的效果，体现了 EEMD-SE 算法的准确性；最后根据隧道通风设备以及隧道的环境特点，设计了一种结合实时故障诊断功能的公路隧道风机监控系统。

总结与展望

总结

及时对公路隧道通风设备进行状态判断与故障诊断,有利于通风设备的维护,从而保障隧道通风系统的正常运行,对公路隧道的安全高效运营有着积极作用。本文以公路隧道通风设备故障诊断为重点,首先分析了公路隧道通风设备结构,确定了通风设备主要结构为轴流式风机;其次根据该结构搭建了风机故障实验台,并通过公路隧道通风风机的故障类别分析,确定需要模拟的故障内容;然后完成了对风机故障的模拟并通过基于 stm32 单片机的数据采集系统完成数据的采集;再次根据采集的故障数据提出了 EEMD-SE 故障诊断模型,并通过故障数据验证了有效性和准确性;最后设计了一种包含实时故障诊断功能的公路隧道风机监控系统,用以实现对公路隧道通风风机的实时监控与实时故障诊断,本文主要工作如下:

(1) 分析作为公路隧道通风设备主体的轴流风机和射流风机结构,确定其结构同属于离心式风机、轴流式风机、斜流式风机和横流式风机结构中的轴流式风机结构;其次通过分析公路隧道通风风机的故障,确定了叶轮故障、电机故障、固定结构故障和电源故障四种故障类型;然后根据轴流风机和射流风机同属的轴流式风机结构完成风机故障实验台的设计与实现。

(2) 通过风机故障实验台,模拟了正常状态、叶轮松动状态、转子断条状态、电压不足状态以及固定件松动状态这 5 种状态,设计并实现了基于 stm32 单片机的故障数据采集系统,完成了风机故障 6 维振动信号的采集与存储,为后续的故障诊断算法模型提供数据支撑。

(3) 完成采集的风机故障数据分析与集合经验模态分解后的数据特征分析,提出了一种基于集合经验模态分解与注意力机制的 EEMD-SE 故障诊断模型。并与卷积神经网络、支持向量机和多层感知机等经典算法进行对比分析,验证了本文提出的故障诊断模型对风机故障数据判断的准确性。

(4) 根据公路隧道通风设备以及公路隧道的环境特点,结合本文提出的公路隧道通风设备故障诊断模型,提出了一种结合隧道风机故障诊断功能的监控系统,并完成了公路隧道通风设备监控模块的结构设计。

展望

对于公路隧道通风设备故障诊断研究，下一步的方向可以围绕以下进行。

（1）公路隧道通风设备可能同时出现两种及以上的故障，所产生的振动信号与单一故障所产生的振动信号会有所不同。本文只针对单一故障进行了模拟与故障诊断模型的建立，对于多种故障共同作用的故障诊断还未进行研究。对通风设备的多故障诊断可以作为下一步的研究方向。

（2）在搭建风机故障实验台时，首先使用了 51 单片机，由于其主频较低而造成采样率同样较低，所采集的信息特征不明显，因此更换了更高主频的 STM32。后续可以对低采样率下的信号建立故障诊断模型，可以起到故障诊断模块降低成本，减少模型运算量的作用。

参考文献

- [1] 2021 年交通运输行业发展统计公报 - 政府信息公开 - 交通运输部 [EB/OL]. http://www.gov.cn/xinwen/2022-05/25/content_5692174.htm, 2022-05-25
- [2] 徐志胜, 王蓓蕾, 孔杰, 等. 风机横向布置间距对公路隧道污染物分布的影响研究[J]. 安全与环境学报, 2021, 21(01): 321-327.
- [3] 钟正强, 刘波, 喻奕. 新型隧道风机支承结构承载力检测试验装置与试验方法[J]. 中外公路, 2015, 35(02): 181-185.
- [4] 刘琦, 赵卫斌, 刘松荣, 等. 公路隧道悬挂风机基础稳定性检测方法[J]. 公路交通技术, 2018, 34(01): 126-128.
- [5] 谭帅, 马遥, 侍洪波, 等. 基于时序关联分析的旋转机械故障诊断[J]. 振动与冲击, 2022, 41(08): 171-178.
- [6] 许伯强, 何俊驰, 孙丽玲. 基于 SAE 与改进 LightGBM 算法的笼型异步电机故障诊断方法[J]. 电机与控制学报, 2021, 25(08): 29-36.
- [7] 李晗, 萧德云. 基于数据驱动的故障诊断方法综述[J]. 控制与决策, 2011, 26(01): 1-9.
- [8] 肖乾浩. 基于机器学习理论的机械故障诊断方法综述[J]. 现代制造工程, 2021(07):148-161.
- [9] Niu L, Cao H, He Z, et al. Dynamic Modeling and Vibration Response Simulation for High Speed Rolling Ball Bearings With Localized Surface Defects in Raceways[J]. Journal of Manufacturing Science and Engineering, 2014, 136(04): 152-161.
- [10] Bagheri F, Khaloozadeh H, Abbaszadeh K. Stator fault detection in induction machines by parameter estimation, using adaptive kalman filter[C]. 2007 Mediterranean Conference on Control & Automation. IEEE, 2007: 1-6.
- [11] Zhao L, Ge B, Gao H, et al. Fault-Tolerant Control for Reducing Harmonic Distortion of Dual Three-Phase Permanent Magnet Synchronous Motor[J]. Energies, 2022, 15(11): 1-20.
- [12] 李宏, 王崇武, 贺昱曜. 基于参数估计模型的对转永磁无刷直流电机实时故障诊断方法[J]. 西北工业大学学报, 2011, 29(05): 732-737.
- [13] Wu J D, Wang Y H, Bai M R. Development of an expert system for fault diagnosis in scooter engine platform using fuzzy-logic inference[J]. Expert Systems with Applications, 2007, 33(04): 1063-1075.
- [14] Matsuyama M. An algorithm for diagnosis of system failures in the chemical process[J]. Computers & Chemical Engineering, 1979, (01): 489-493.
- [15] 刘友宽, 苏适, 杨洋, 等. 基于 SDG 模型的风力发电机故障诊断方法[J]. 机械强度, 2013, 35(05): 583-588.
- [16] Venkatasubramanian V, Rengaswamy R, Yin K, et al. A review of process fault detection and diagnosis: Part I: Quantitative model-based methods[J]. 2003, 27(03): 293-311.

- [17] 周东华, 胡艳艳. 动态系统的故障诊断技术[J]. 自动化学报, 2009, 35(06): 748-758.
- [18] Grossmann A, Morlet J. Grossmann, A. & Morlet, J. Decomposition of Hardy functions into square integrable wavelets of constant shape. SIAM J. Math. Anal. 15, 723-736[J]. siam j.math.anal, 2006, 15(04): 723-736.
- [19] 李世玲, 李治, 李合生. 基于小波包能量特征的滚动轴承故障监测方法[J]. 系统仿真学报, 2003, (01): 76-80.
- [20] Burriel-Valencia J, Puche-Panadero R, Martinez-Roman J, et al. Short-Frequency Fourier Transform for Fault Diagnosis of Induction Machines Working in Transient Regime[J]. IEEE Transactions on Instrumentation and Measurement, 2017, 66(3): 432-440.
- [21] 张邦基, 于德介, 杨胜. 基于小波变换与粗集理论的滚动轴承故障诊断[J]. 中国机械工程, 2008, 15: 1793-1795.
- [22] 黄华, 薛文虎, 姚嘉靖, 等. 基于图论诊断法与小波包变换的数控机床进给系统故障诊断研究[J]. 振动与冲击, 2022, 41(15): 130-137.
- [23] 郑海波, 李志远, 陈心昭. 基于连续小波变换的齿轮故障诊断方法研究[J]. 机械工程学报, 2002, 03: 69-73.
- [24] Liu Z, Fang L, Jiang D, et al. A Machine-Learning-Based Fault Diagnosis Method With Adaptive Secondary Sampling for Multiphase Drive Systems[J]. IEEE Transactions on Power Electronics, 2022, 37(8): 8767-8772.
- [25] 段艳杰, 吕宜生, 张杰, 等. 深度学习在控制领域的研究现状与展望[J]. 自动化学报, 2016, 42(5): 643-654.
- [26] Zhang D, Han X, Deng C. Review on the research and practice of deep learning and reinforcement learning in smart grids[J]. 中国电机工程学会电力与能源系统学报, 2018, 4(03): 362-370.
- [27] Windridge D, Bober M. A Kernel-Based Framework for Medical Big-Data Analytics[J]. Springer Berlin Heidelberg, 2014, 84(01): 197-208.
- [28] 赵光权, 葛强强, 刘小勇, 等. 基于 DBN 的故障特征提取及诊断方法研究[J]. 仪器仪表学报, 2016, 37(09): 1946-1953.
- [29] Önel I Y, Benbouzid M E H. Induction Motor Bearing Failure Detection and Diagnosis: Park and Concordia Transform Approaches Comparative Study[J]. IEEE/ASME Transactions on Mechatronics, 2008, 13(2): 257-262.
- [30] 张淑清, 胡永涛, 姜安琦, 等. 基于双树复小波和深度信念网络的轴承故障诊断[J]. 中国机械工程, 2017, 28(05): 532-536+543.
- [31] 蒋爱国, 符培伦, 谷明, 等. 基于多模态堆叠自动编码器的感应电机故障诊断[J]. 电子测量与仪器学报, 2018, 32(08): 17-23.
- [32] 赵洪山, 闫西慧, 王桂兰, 等. 应用深度自编码网络和 XGBoost 的风电机组发电机故障诊断[J].

- 电力系统自动化, 2019, 43(01): 81-86.
- [33] Ince T, Kiranyaz S, Eren L, et al. Real-Time Motor Fault Detection by 1D Convolutional Neural Networks[J]. IEEE Transactions on Industrial Electronics, 2016, 63(11): 7067-7075.
- [34] Liu Z, Fang L, Jiang D, et al. A Machine-Learning-Based Fault Diagnosis Method With Adaptive Secondary Sampling for Multiphase Drive Systems[J]. IEEE Transactions on Power Electronics, 2022, 37(8): 8767-8772.
- [35] 唐静远, 师奕兵. 采用模糊支持向量机的模拟电路故障诊断新方法[J]. 电子测量与仪器学报, 2009, 23(06): 7-12.
- [36] Lee J, Nam S, Park S. Energy-Efficient Control of Mobile Processors Based on Long Short-Term Memory[J]. IEEE Access, 2019, 07: 80552-80560.
- [37] 李仲兴, 秦霞, 薛红涛. 基于 BN 和改进 DST 的轮毂电机故障诊断方法[J]. 华中科技大学学报: 自然科学版, 2021, 49(08): 27-32.
- [38] 李智雄. 基于物联网的智慧化公路机电养护系统[J]. 交通世界, 2019, 19: 10-11.
- [39] 周晓旭. 高速公路机电设备使用寿命评估方法研究[J]. 山西交通科技, 2020, 02: 106-110.
- [40] 朱立伟. 公路隧道机电系统运行风险实时评估技术[J]. 公路, 2017, 62(12): 176-181.
- [41] 徐建国, 黄广臣. 高速公路机电设备故障多因素预测模型应用研究[J]. 建筑机械, 2022, 09: 20-23.
- [42] 沈家怡. PHM 技术在公路隧道运营中的应用探讨[J]. 现代信息科技, 2020, 04(06): 128-131.
- [43] 单位招商局重庆交通科研设计院有限公司. 中华人民共和国行业推荐性标准公路隧道通风设计细则[M]. 人民交通出版社股份有限公司, 2014.
- [44] 王加浩, 乔洋, 田晨晔, 等. 仿鲤科鱼 C 型启动多翼离心风机叶片性能研究[J]. 工程热物理学报, 2022, 43(09): 2363-2373.
- [45] 印玮, 杨爱玲, 陈二云, 等. 仿生轴流风机气动噪声特性的实验研究[J]. 热能动力工程, 2022, 37(10): 51-59.
- [46] 侯志泉, 杨明智, 梁习锋, 等. 机车斜流风机的流场数值分析与设计优化[J]. 空气动力学学报, 2018, 36(02): 300-306.
- [47] 李吉成, 果霖, 马艳丽, 等. 联合收割机横流风机流场的数值模拟[J]. 江苏农业科学, 2015, 43(09): 439-441.
- [48] 秦晓梅, 巢明, 程春雨, 等. 传统单片机对 IIC 总线通信模拟编程的优化研究[J]. 工业和信息化教育, 2019, 10: 39-43.
- [49] 李文明, 浮明军, 赵维毅. 国产化龙芯处理器 IIC 总线故障分析与改进[J]. 电工技术, 2022, 14: 111-112.
- [50] 郭宝军, 高贝贝, 崔金龙, 等. 基于 RS232 接口的交流电源系统设计[J]. 光源与照明, 2021, 04: 64-65.
- [51] 杨纯, 李垠韬, 宋伟, 等. Φ -OTDR 光纤传感电缆防外破监测数据预处理方法[J]. 激光与红外,

- 2021, 51(04): 486-492.
- [52] 宋勇, 蔡志平. 大数据环境下基于信息论的入侵检测数据归一化方法[J]. 武汉大学学报(理学版), 2018, 64(02): 121-126.
- [53] 杨克克, 罗阳, 赵忆文, 等. 基于主方向傅里叶变换算子的 2D/3D 分级配准[J]. 机器人, 2021, 43(03): 296-307.
- [54] 闫文康, 闫毅, 范亚楠, 等. 基于小波变换熵值及高阶累积量联合的卫星信号调制识别算法[J]. 空间科学学报, 2021, 41(06): 968-975.
- [55] Li G, Song Y, Lv Y, et al. Clinical Characteristics and Prognostic Analysis of Multiple Myeloma with Extramedullary Disease: A SEER-Based Study[J]. Journal of Oncology, 2021, 2021: 1-9.
- [56] Cheng X, Mao J, Li J, et al. An EEMD-SVD-LWT algorithm for denoising a lidar signal[J]. Measurement, 2021, 168: 108405.
- [57] Bhatt D, Patel C, Talsania H, et al. CNN Variants for Computer Vision: History, Architecture, Application, Challenges and Future Scope[J]. Electronics, 2021, 10(20): 2470.
- [58] 易聪, 杜建军, 尹际雄, 等. 基于转子端数据驱动 LSTM-CNN 模型的高速旋转系统运行状态识别方法[J]. 机械工程学报, 2022: 1-10.
- [59] 郭应时, 黄涛. 基于注意力机制的多模态自动驾驶行为决策模型[J]. 中国公路学报, 2022, 35(09): 141-156.
- [60] 余帅, 汪西莉. 含多级通道注意力机制的 CGAN 遥感图像建筑物分割[J]. 中国图象图形学报, 2021, 26(03): 686-699.