

PHM 技术在公路隧道运营中的应用探讨

沈家怡

(浙江科技学院, 浙江 杭州 310013)

摘要: 随着国家主干道计划的实施、公路隧道的规模不断增加, 所涉及的机电设备数量和种类也日益庞大。但国内对隧道机电设备的后续管理和维修体系尚未成熟, 因此提出了 PHM 技术以完善现有体系, 介绍了 PHM 系统建模的主要方法, 分析了公路隧道机电设备的工作特性, 提出了基于数据驱动的射流风机 PHM 建模方法, 通过交叉验证完成了模型测试, 证明了将 PHM 技术运用到隧道运营中具有一定的可行性。

关键词: 故障预测和健康管理; 隧道机电; 数据驱动; 射流风机

中图分类号: U453.5

文献标识码: A

文章编号: 2096-4706 (2020) 06-0120-04

The Application of PHM in Highway Tunnel Operation

SHEN Jiayi

(Zhejiang University of Science and Technology, Hangzhou 310013, China)

Abstract: With the implementation of the national trunk road plan, the scale of road tunnel is increasing, and the number and types of electromechanical equipment are also increasing. But domestic follow-up of tunnel mechanical and electrical equipment management and maintenance system is not yet mature. Therefore puts forward the fault prediction and health management (PHM) techniques to improve the existing system, introduced the main methods of PHM system modeling, analyzed the working characteristic of highway tunnel electromechanical equipment, put forward the modeling method based on data driven, cross validation completed test, proved the PHM technology applied to the tunnel operation has certain feasibility.

Keywords: failure prediction and health management; tunnel electro mechanical; data-driven; jet fan

0 引言

中国地域幅员辽阔, 地势复杂, 而其中山地和丘陵约占全国土地总面积的 43%。为了保证交通的快捷性和便利性, 必须修建大量隧道贯穿山岭以连接两地。截至 2017 年末, 全国公路隧道共计 16 229 处、总里程为 1 528.51 万米, 比 2016 年增加 1 048 处、124.54 万米。其中: 特长隧道 (指 > 3 km 的公路隧道) 902 处、里程 401.32 万米; 长隧道 (指 1 km ≤ l ≤ 3 km 的公路隧道) 3 841 处、里程 659.93 万米^[1]。中国是名副其实的隧道建设大国。但国内后续对隧道的故障检修及养护管理体系研究较少, 如何科学有效地维修和管理隧道设备尤其是易损易磨的机电系统成为了隧道运营管理者亟需解决的问题之一。本文以本校合作研究院的机电数据平台为基础, 设计了一种以公路隧道射流风机为研究对象的 PHM 模型, 在一定程度上对风机进行故障预测, 辅助管理人员对隧道机电设备的维修决策。

1 故障预测和健康管理

故障预测和健康管理 (PHM) 是一种可靠的工程方法, 其利用信号传感、机器学习、物理失效等建模技术, 提供实时的健康评估并预测其未来运行状态^[2]。PHM 技术起源于二十世纪七十年代, 最早的典型案例是美国军方运用在 A-7E

飞机发动机上的监控系统 (EMS)^[3]。经过 40 余年的发展, PHM 技术现已广泛运用于民用飞机、轮船、汽车、工业设备、消费类电子和医疗设备等系统的设计和使用中^[4], PHM 系统的功能包括: 设备状态实时监控、故障预测、对某选定组件进行状态预测、对寿命有限的组件进行寿命跟踪、健康管理等功能^[5]。

关于 PHM 方法的分类, 目前尚不统一。目前主流的分类方法为 Byington CS、Roemer MJ、Galie T^[6] 提出的基于模型驱动的故障预测方法、基于数据驱动的故障预测方法和基于知识的故障预测方法三类。根据用于数据驱动和模型驱动方法中建模方法的不同, 又可以将 PHM 进行进一步的细分。例如数据驱动方法可以分为统计方法和机器学习方法, 模型驱动方法可分为系统建模方法和物理失效建模方法^[7]。经过后续 PHM 技术的发展又出现了结合基于数据驱动和模型驱动各自优势的融合预测方法。

1.1 基于模型驱动的 PHM 技术

基于模型驱动的故障预测方法主要通过数学模型来描述系统的物理特性。根据建模方法的不同可以分为系统建模方法和物理失效建模方法^[8]。

1.1.1 系统建模方法

在系统建模方法中, 通过构造一系列数学函数、映射来建立物理系统的数学模型, 通过计算监测数据和数学模型的残差来统计估计系统的健康状态。统计估计的方法包括

收稿日期: 2020-03-08

Kalman 滤波、参数估计和奇偶相关法。

1.1.2 物理失效建模方法

产品在制造、运输、存储、处理、操作和非操作过程中会受到外力负载。这些生命周期中的负载(热、机械、化学、电等)会单独或同时作用于产品,从而导致产品性能下降或物理性能退化,并缩短其使用寿命。其退化程度和速率取决于负载的强度和持续时间。物理失效建模(PoF)基于识别产品的潜在失效模式、失效机制和失效区域,并将其作为设备生命周期的条件函数,每个失效点应力的数学表达都是关于负载条件、几何形状和材料性能的函数。然后再根据失效模型来确定故障的产生和传递^[9]。使用该方法的前提条件为:设备故障是由基本的机械、化学、电气、热和辐射过程而产生的。

1.2 基于数据驱动的故障预测方法

数据驱动方法被认为是 PHM 的黑箱方法,因为它不需要系统模型或系统的特定参数即可进行预测^[8]。只需要设备的历史和实时监测数据用来了解系统状态。因此,基于数据驱动的方法适用于复杂系统。该方法的实现通常基于这样的假设:直到出现故障,系统性能的统计特征才会改变^[8]。数据驱动方法的特点是:底层算法实现速度更快,计算效率更高,但是必须要有足够的历史数据和典型的操作性能数据、相关的临界阈值及其边界,其可靠性依赖于从传感器获取的数据和对这些数据的分析。数据驱动方法又可以分为统计方法和机器学习方法。

1.2.1 统计方法

统计方法的核心是使用统计参数(例如均值、方差、中位数等),基于已知或未知的基础概率分布进行故障预测。如果已知基础概率分布,则通常认为统计方法较其他数据驱动方法更加简单,这种方法称为参数方法。在这种情况下,可以采用统计参数估计和假设检验来检测数据中是否存在异常。不过大多数真实世界的可靠性数据的概率分布是未知的,所以首先需要构建这些数据的概率函数。这种方法称为非参数方法,它为计算带来了更大的灵活性。因此,非参数方法可以看作是统计方法的通用方法。PHM 的一种广泛使用的非参数方法是通过直方图分析,估计密度函数则较多使用核方法。

1.2.2 机器学习方法

在 PHM 系统中,机器学习方法主要通过历史数据和算法来构建预测模型。模型构建完成后,可根据实时数据进行健康评估并预测其未来运行状态。按所选择的算法不同又可分为监督学习和无监督学习。

目前用于故障预测及分类的监督学习算法包括决策树、贝叶斯网络、神经网络、支持向量机(SVM)。

无监督学习算法包括了主成分分析(PCA)、k 均值聚类、卡尔曼滤波器以及同样可以在无监督学习中使用的神经网络。

1.3 基于知识的故障预测方法

由于在实际工程运用中,有些设备因为结构或其他原因无法进行准确的建模,同时也没有足够的传感器来提供

数据支持,所以无法使用上述的故障预测方法。而基于知识的故障预测方法仅需要领域专家的经验知识和少量的数据支持。可以作为 PHM 技术在特殊情况下的补充。目前,基于知识的 PHM 系统建模技术主要包括专家系统和模型逻辑等方法。

1.4 融合预测方法

融合预测方法是数据驱动方法和模型驱动方法的结合。因基于物理失效建模的预测方法需要系统的准确数学模型。而基于数据驱动的预测方法则需要足够的历史数据和操作性能数据。融合预测方法则克服了模型驱动和数据驱动方法两者的局限性,对于剩余使用寿命(RUL)的估计可以达到很高的准确度^[6]。但对于实时分析而言,其所需的计算资源可能不足以支撑其预测。

2 射流风机的 PHM 系统建模分析及验证

机电设备在隧道运营过程中会积累大量历史数据,这些数据一部分可以作为数据驱动方法中机器学习的训练集来建立预测模型,另一部分可以作为验证集以验证模型的泛化性。实际使用时只需输入机电设备的实时监测数据,模型就可根据这些数据得到对未来运行状态的趋势预测。下面以通风子系统中的射流风机为例,验证将 PHM 技术运用于公路隧道运营中的可行性。

通风系统作为隧道机电系统中的关键子系统之一,起着向外排出机动车废气,向内输入流动的自然空气的作用,可以有效地进行隧道内外的空气置换。防止公路隧道中有害气体堆积对机动车驾驶人员和行人的身体健康产生危害,同时高浓度的废气堆积也会影响驾驶人员的行车视线,甚至在某些极端条件下还会引起爆炸。因此通风系统的正常运行对保持整个隧道的安全质量和服务质量有着重要作用。

目前大部分的公路隧道均采用纵向通风方式。纵向通风分为如图 1 所示的射流式、竖井式、风道式以及喷嘴式。射流式纵向通风是将射流式风机置于车道的吊顶部,吸入隧道内的部分空气,并以 30 m/s 左右的速度射吹出,用以升压,使空气加速,达到通风的目的^[10]。




图 1 射流式隧道通风

而射流风机作为隧道通风子系统的重要组成部分之一,其运行状态决定了整个隧道的通风质量。所以有必要对射流风机的运行状态进行实时监测,根据监测数据进行故障预测,根据预测结果进行事前维修,降低设备故障对隧道正常通行产生的影响。

基本的研究流程为:

- (1) 确定特征参数并安装传感器以获得数据;
- (2) 对数据进行预处理;
- (3) 选用合适的算法搭建模型;
- (4) 验证测试模型;
- (5) 修改模型;
- (6) 根据模型计算结果辅助维修方案的决策。

2.1 传感器安装

常见的射流风机由消声器、风机本体和吊装支架构成。风机本体又包括电机和风机叶轮两个部分。风机在运行过程遇到的主要故障主要分为三类:

- (1) 电机运行异常, 包括电机轴承故障或电机运行温度过高;
- (2) 风机的固定部件松动;
- (3) 叶轮不平衡^[11]。

针对上述故障, 射流风机的数据采集宜采用两个振动传感器, 分别采集径向水平和垂直方向的振动; 一个温度传感器, 用以采集电机轴温; 三个电流传感器, 用以采集三相电流; 三个电压传感器, 用以采集三相电压; 一个转速传感器, 用以采集风机转速。

2.2 数据预处理

数据的预处理可以分为异常剔除、缺失剔除、特征降维和信号降噪。异常和缺失剔除是为了去除随机大峰值信号和传感信号丢失对模型建立的干扰。对于机器学习而言, 一个模型的输入特征向量维度越高, 其获得的最终模型就越精确。然而在实际训练中, 高维度特征向量的输入往往会引起算法的计算量大量增加, 且这些特征向量中包括了与故障发生并无联系的干扰特征以及大量噪声, 为此还需对数据进行进一步的处理。

2.2.1 主成分分析 (PCA)

在实际情况中, 输入向量的特征之间可能存在一定的相关性, 这也意味着特征与特征之间存在重叠信息。PCA 算法可以在剔除一部分特征属性的同时保留原始数据的大部分信息, 以达到降维的目的。PCA 算法的基本原理是: 一个高维数据集如果能够被相关变量表示, 那么只有一些维的数据才有意义, 这些数据包含了最多的信息。其数学方法为通过正交线性变换, 将数据的坐标按照其方差的大小进行排序, 得到各个主成分^[12]。假设有数据集 D 包含 m 个样本, 每个样本的特征数据为 x , 样本标签为 y , 则有:

$D_i = \{ (x_i, y_i) | x_i \in R, y_i \in N^+, m=1, \dots, k, i=1, \dots, m \}$, PCA 围绕特征数据展开, 首先剔除 y_i 再对 x 进行中心化, 得到 D^1 :

$$D^1 = \{ z_i | z_i \in R, i=1, \dots, n \}$$

$$\text{其中 } z_i = x_i - \frac{1}{n} \sum_{i=0}^n x_i$$

再计算 D^1 协方差矩阵 S :

$$S = \begin{pmatrix} \text{cov}(z_1, z_2) & \cdots & \text{cov}(z_n, z_1) \\ \vdots & \ddots & \vdots \\ \text{cov}(z_1, z_n) & \cdots & \text{cov}(z_n, z_n) \end{pmatrix}$$

对 S 进行特征分解, 得到特征值 Λ 与对应的特征向量

Q , 其中 Λ 的大小代表了该特征值所对应的特征向量 Q 所包含的信息量。将特征值排序后丢弃排名靠后的部分, 并将剩余特征值所对应的特征向量构成矩阵 M 。

$$x' = z * M$$

x' 即为降维后的训练数据。

2.3 模型算法

2.3.1 支持向量机

支持向量机 (Support Vector Machine, SVM), 在机器学习属于监督式学习模式, 即对于给定的训练样本集 $D = \{ (x_1, y_1), (x_2, y_2), \dots, (x_m, y_m) \}$, 每个样本的类别标记 y 都需已知, 在故障预测中可令 $y_i \in \{-1, +1\}$ 。

SVM 用于分类学习时, 其最基本的思想就是基于给定的训练集 D , 在样本空间中找到一个划分超平面:

$$w^T x + b = 0$$

使得样本到平面的几何间隔取到最大。对于线性可分的训练数据而言, 线性可分离平面有无穷多个, 但是几何间隔最大的分离超平面是唯一的。为了表示不同分离超平面的区分效果, 引入间隔 γ 表示训练集 D 中离超平面最近的样本点到超平面的距离:

$$\gamma = \frac{w^T x + b}{\|w\|}$$

在超平面已知的情况下, γ 值越大, 说明超平面的划分效果越好, 模型的鲁棒性越强。因此 SVM 算法的目标就是求解下述方程:

$$\max \gamma = \max \frac{w^T x + b}{\|w\|}$$

$$s.t. \Rightarrow y_i (w^T x + b) \geq 1, \forall i = 1, \dots, l$$

2.3.2 核方法

上述方法中, 给定的训练样本是线性可分的, 即存在一个划分超平面能将训练样本正确分类。然而在实际情况中, 训练样本可能不是线性可分的, 即在原始样本空间中并不存在划分超平面。此时可将样本从原始空间映射到一个更高维的空间, 使得样本在此空间中线性可分^[13]。存在现有定理如下: 如果原始样本属性特征有限, 那么一定存在一个高维特征空间使样本可分。解决问题的关键就转化为了选择合适的核函数, 使得样本能在保留原始信息的前提下, 映射到更高维的空间。

表 1 列出了几种常用的核函数。

表 1 常用核函数

名称	表达式	参数
线性核	$\tau(x_i, x_j) = x_i^T x_j$	
多项式核	$\tau(x_i, x_j) = (x_i^T x_j)^d$	$d \geq 1$
高斯核	$\tau(x_i, x_j) = \exp\left(-\frac{\ x_i - x_j\ ^2}{2\sigma^2}\right)$	$\sigma \geq 0$
拉普拉斯核	$\tau(x_i, x_j) = \exp\left(-\frac{\ x_i - x_j\ }{\sigma}\right)$	$\sigma \geq 0$
Sigmoid 核	$\tau(x_i, x_j) = \tanh(\beta x_i^T x_j + \theta)$	$\beta > 0, \theta < 0$

2.4 模型建立与验证

模型的建立主要利用了 Python 及机器学习相关库。数据导入，查询部分数据如表 2 所示。

对数据进行标准化后，进行 PCA 降维。将数据集分成训练集和验证集，并在模型训练时加入参数网格寻优和交叉验证，以提高模型的预测准确性及泛化性。

表 2 部分数据

时间 (s)	温度 (℃)	X 轴振动 (mm/s)	Y 轴振动 (mm/s)	A 相电流 (A)	B 相电流 (A)	C 相电流 (A)	A 相电压 (V)	B 相电压 (V)	C 相电压 (V)	转速 (rpm)	标记
0	24.99	0.07	0.16	0.00	0.00	0.00	0.00	0.00	0.00	0.00	1
0.5	25.23	2.06	1.69	47.25	49.84	48.84	28.17	27.09	28.14	4	1
1.0	25.49	3.95	3.24	93.22	92.13	90.52	55.27	55.37	56.97	24	1
1.5	26.43	5.83	4.95	135.05	138.82	137.66	81.63	80.17	82.40	50	1
2.0	26.94	8.43	6.11	182.63	184.20	183.04	111.38	108.55	85.00	85	1

经验证集验证，当选择高斯核为核函数，且参数选择如下所示时，模型的预测准确率可达到 96%：

```
SVC(C=1.0,cache_size=200,class_weight=None,coef0=0.0,decision_function_shape='ovr',  
Degree=2,gamma=5,kernel='rbf',max_iter=-1,  
probabiblity=False,random_state=1,shrinking=True,tol=0.001,vervose=False)
```

C：惩罚系数

degree：degree 决定了多项式的最高次幂

gamma：即高斯核中的 σ

kernel：核函数，rbf 即为高斯核

3 结 论

PHM 技术利用传感技术、机器学习、数学建模等方法对设备进行实时的健康评估并预测其未来运行状态，进而完成对设备的预知维修，防止产生设备故障带来的负面影响，具有广阔的运用前景。本文介绍了几种典型的 PHM 方法，并利用数据驱动方法中的机器学习，对隧道机电系统中的射流风机进行了建模，达到了预期目标，证明了将 PHM 技术运用到隧道运营中具有一定的可行性。

参考文献：

[1] 佚名. 截至 2017 年末中国大陆公路隧道数据 [J]. 隧道建设 (中英文), 2018, 38 (3) : 398.
[2] QU Y J, MING X G, QIU S Q, et al. An Integrative Framework for Online Prognostic and Health Management Using Internet of Things and Convolutional Neural Network [J].Sensors, 2019, 19 (10) .
[3] 曾声奎, Michael G.Pecht, 吴际. 故障预测与健康管理 (PHM) 技术的现状与发展 [J]. 航空学报, 2005 (5) : 626-632.

[4] 李春. 故障预测与健康管理 (PHM) 技术介绍 [J]. 中国高新技术企业, 2008 (15) : 43-44.

[5] HESS A, CALVELLO G, DABNEY T. PHM a key enabler for the JSF autonomic logistics support concept [C]// IEEE Aerospace Conference. IEEE, 2004: 3543-4549.

[6] BYINGTON C.S, ROEMER M.J, GALIE T. Prognostic enhancements to diagnostic systems for improved condition-based maintenance [C]//Aerospace Conference Proceedings, IEEE, 2002: 2815-2824.

[7] SUTHARSSAN T, STOYANOV S, BAILEY C, et al. Prognostic and health management for engineering systems: a review of the data-driven approach and algorithms [J]. The Journal of Engineering, 2015.

[8] PECHT M, JAAI R. A prognostics and health management roadmap for information and electronics-rich systems [J]. Microelectronics Reliability, 2010, 50 (3) : 317-323.

[9] PECHT M, GU J. Physics-of-failure-based prognostics for electronic products [J]. Transactions of the Institute of Measurement and Control, 2009, 31 (3-4) : 309-322.

[10] 杨超, 王志伟. 公路隧道通风技术现状及发展趋势 [J]. 地下空间与工程学报, 2011, 7 (4) : 819-824.

[11] 倪伟, 李世立. 基于振动分析的射流风机故障诊断与健康监测方法 [J]. 现代信息科技, 2019, 3 (17) : 140-142+144.

[12] 李永亮. 基于机器学习的故障预测与健康管理 (PHM) 方法研究 [D]. 成都: 电子科技大学, 2017.

[13] 柏帆. 支持向量机辅助卡尔曼滤波在不动产实地调查技术中的研究 [D]. 南京: 东南大学, 2018.

作者简介：沈家怡 (1995-)，男，汉族，浙江宁波人，研究生在读，研究方向：隧道机电。